

# Utilisation de graphes pour la classification et l'extraction de structures

## Généralisation à des interactions d'ordre supérieur

Soutenance de thèse, mardi 8 septembre 2026

Learning Centre SophiaTech, Université Côte d'Azur

Louis HAUSEUX (Centre Inria d'Université Côte d'Azur; bourse 3IA-DS4H)

Thèse dirigée par Konstantin AVRACHENKOV (Inria, éq. NEO) et co-encadrée par Josiane ZERUBIA (Inria, éq. AYANA)

Rapporteurs : Dieter MITSCHÉ (PUC de Chile), Hocine CHERIFI (Univ. Bourgogne Europe)

Examineurs : Nicolas NISSE (Inria, éq. COATI), Pierre CHARBONNIER (Cerema), Zoltán KATÓ (Univ. de Szeged)

AI CLUSTER  
**3IA CÔTE D'AZUR**

ÉCOLE UNIVERSITAIRE DE RECHERCHE  
**SYSTÈMES NUMÉRIQUES  
POUR L'HUMAIN**

# 01

## Prologue : une ancienne énigme



## Une ancienne énigme...

Un classificateur non-supervisé utilisant les  
*complexes simpliciaux*  
(avec une application à la *stylométrie*).

LOUIS HAUSEUX  
Encadré par BARTŁOMIEJ BŁASZCZYSZYN



juillet 2017

Avant-propos

Stage à l'Inria Paris, équipe DYOGENE-MATHNET **[HAL 17]**

**[HAL 17]** L. Hauseux (encadré par B. Błaszczyszyn), « Un classificateur non supervisé utilisant les complexes simpliciaux », Inria Paris, 2017. HAL : hal-01597846.

# Le sujet à la mode : l'homologie *persistante*



Faire croître un rayon  $r$  ; regarder les structures **naître, vivre, mourir** [Ghrist 08] [ToMATo 13]


[Ghrist 08] R. Ghrist, « Barcodes : the persistent topology of data », Bulletin of the AMS, 2008.

[ToMATo 13] F. Chazal, L. J. Guibas, S. Y. Oudot, P. Skraba, « Persistence-based clustering in Riemannian manifolds » (ToMATo), *J. ACM*, 60(6), art. 41, 2013.





## ...avec une application à la *stylométrie*




- ▶ Une matrice de **Gram** : similarité  $500 \times 500$  entre articles de presse [HAL 17]
- ▶ **5 auteurs** anonymes, 100 articles chacun (statistiques de style : vocabulaire, catégories grammaticales, ponctuation, etc.)
- ▶ **But (non supervisé)** : rendre à chaque auteur ses 100 articles

Ici, les articles sont *triés* par auteur ; l'algorithme, lui, ne voit qu'une matrice mélangée



## Une heuristique inspirée de la persistance




- Faire croître le seuil de similarité
- Observer les composantes « **triangles-connexes** »  
(des  $k$ -simplexes recollés par facettes)
- Les voir **naître, grandir, fusionner**
- S'arrêter : une proportion  $P$  est couverte

Les « polyèdres » retournés ( $k = 2$ ) [HAL 17]



## Et... cela marche bien



- ▶ **2 auteurs** : 1 erreur, 1 article non classé (sur 100)
- ▶ Mieux que l'algorithme des  $k$ -moyennes...
- ▶ ... et que des mélanges gaussiens *semi-supervisés*
- ▶ Et sur **5 auteurs** : 4 amas retrouvés

Analyse en composantes principales : deux auteurs sur cinq

# Pourquoi cela marche-t-il si bien ?

# Plan

- I) Prologue : une ancienne énigme
- II) Du *Single-Linkage* à ses fondements
- III) Monter à l'**ordre supérieur** : la hiérarchie  $K$ -NN exacte
- IV) La **percolation** comme mesure de performance
- V) Applications : LiDAR 3D et 4D, sans apprentissage
- VI) Vers des données davantage structurées
- VII) Perspectives : la voie **hiérarchique**
- VIII) Conclusion


# 02

## Du *Single-Linkage* à ses fondements



# Le *clustering* sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^p$

## Modèle de Hartigan [Hartigan 81] : les amas de forte densité




[Hartigan 81] J. A. Hartigan, « Consistency of Single Linkage for high-density clusters », JASA, 1981.


[Campello 13] R. Campello, D. Moulavi, J. Sander, « Density-based clustering based on hierarchical density estimates » (HDBSCAN), PAKDD, 2013.



## Deux exemples issus de la thèse



Cosmologie 3D : filaments de galaxies [CN 23]



Huiles d'olive ( $\mathbb{R}^8$ ) : hiérarchie obtenue  
[EUSIPCO 24] [ANS 26]

[CN 23] L. Hauseux, K. Avrachenkov, J. Zerubia, « Graph based approach for galaxy filament extraction », *Complex Networks & Their Applications*, Menton, 2023.

[EUSIPCO 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Benefits of hypergraphs for density-based clustering », *EUSIPCO*, Lyon, 2024.


[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.



# Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau  $\{f \geq \lambda\}$

Arbre hiérarchique




$C_1$




## Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau  $\{f \geq \lambda\}$




Arbre hiérarchique




## Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau  $\{f \geq \lambda\}$




Arbre hiérarchique




## Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau  $\{f \geq \lambda\}$



Arbre hiérarchique





## En pratique : estimer la densité

$$\hat{f} \leftarrow \hat{f}_{K\text{-NN}}$$

Estimateur des  $K$  plus proches voisins [Biau–Devroye 15]


$$\forall y \in \mathbb{R}^p, \quad \hat{f}_{K\text{-NN}}(y) = \frac{K}{n \omega_p r_K(y)^p}$$

$$r_K(y) = \min \{r \geq 0 \mid |B(y, r) \cap (\mathcal{X} \setminus \{y\})| \geq K\}$$

- ▶  $y$  : un point de l'espace, du nuage ou non
- ▶  $n$  : nombre de points de  $\mathcal{X}$
- ▶  $\omega_p$  : volume de la boule unité de  $\mathbb{R}^p$
- ▶  $r_K(y)$  : distance de  $y$  à son  $K^{\text{e}}$  plus proche voisin ; si  $y \in \mathcal{X}$ , on exclut  $y$  lui-même




## Le cas $K = 1$ : un « miracle » géométrique





## Le cas $K = 1$ : un « miracle » géométrique




$$\begin{aligned}\hat{\lambda}(y) &\geq \lambda_0 \\ \Leftrightarrow r_1(y) &\leq r_0\end{aligned}$$

Ensembles de niveau  
= **modèle booléen** [Meester–Roy 96]



## Le cas $K = 1$ : un « miracle » géométrique




$$\hat{\lambda}(y) \geq \lambda_0$$
$$\Leftrightarrow r_1(y) \leq r_0$$

Amas de forte densité  
= **composantes connexes**  
d'un **graphe géométrique** [Penrose 03]





## Le cas $K = 1$ : un « miracle » géométrique




$$r_1(y) \leq r_0$$

Amas de forte densité  
= **composantes connexes**  
d'un **graphe géométrique** [Penrose 03]



## Le cas $K = 1$ : un « miracle » géométrique



$$r_1(y) \leq r_0$$

Amas de forte densité  
= **composantes connexes**  
de l'**arbre minimum couvrant** élagué




# L'arbre minimum couvrant et la triangulation de Delaunay

Cette hiérarchie a un nom :

le **Single-Linkage** [Florek 51]

[Gower–Ross 69]



L'arbre minimum couvrant euclidien est un **sous-graphe** de GABRIEL,

lui-même sous-graphe de DELAUNAY

[Boissonnat 18] :

arbre minimum couvrant  
 $\subseteq$  GABRIEL  $\subseteq$  DELAUNAY


Dans le plan  $\mathbb{R}^2$  :  $\mathcal{O}(n \log n)$

[Florek 51] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, S. Zubrzycki, « Sur la liaison et la division des points d'un ensemble fini », Colloq. Math., 1951.

[Gower–Ross 69] J. C. Gower, G. J. S. Ross, « Minimum spanning trees and Single-Linkage cluster analysis », JRSS C, 1969.

[Boissonnat 18] J.-D. Boissonnat, F. Chazal, M. Yvinec, *Geometric and Topological Inference*, Cambridge University Press, 2018.

## L'effet de chaînage et le *Robust Single-Linkage*




**Effet de chaînage** : une chaîne de points suffit à fusionner deux amas

### *Robust Single-Linkage*

[Chaudhuri–Dasgupta 10] :

- La *core distance*  $r_K(x)$  estime la densité locale
- La distance devient la *mutual reachability*
- Les points isolés sont repoussés

## Les descendants : DBSCAN, puis HDBSCAN



**DBSCAN [Ester 96]** : points *cœurs* ( $r_K(x) \leq r$ ) vs. points *accessibles* : réintègre la frontière des amas

**HDBSCAN [Campello 13]** : fait varier le seuil  $r$  continûment et extrait les amas par excès de masse

$$E(C) = \int_C (f(x) - \lambda) dx$$

[Ester 96] M. Ester, H.-P. Kriegel, J. Sander, X. Xu, « A density-based algorithm for discovering clusters » (DBSCAN), KDD, 1996.

[Campello 13] R. Campello, D. Moulavi, J. Sander, « Density-based clustering based on hierarchical density estimates » (HDBSCAN), PAKDD, 2013.


03

## Monter à l'ordre supérieur : la hiérarchie $K$ -NN exacte




## Que font Robust SL et (H)DBSCAN pour $K = 2$ ?

Nuage de points et boules de rayon  $r$



Arbre hiérarchique obtenu




Un dendrogramme **plat** : toute l'information hiérarchique fine est perdue




## La vraie hiérarchie 2-NN : échelle $r$

Les 2-intersections de boules au niveau  $r$



Arbre hiérarchique




Étape 1 : les 7 segments fusionnent au seuil  $r$





## La vraie hiérarchie 2-NN : échelle $r'$

Triangles et 3-intersections à  $r'$



Arbre hiérarchique




Étape 2 : fusion des triangles à  $r'$  via les 3-intersections. L'arête  $CD$  reste isolée




## La vraie hiérarchie 2-NN : échelle $r''$

Connexité globale à  $r''$




Arbre hiérarchique




Étape 3 : connexité globale à  $r''$  par les points de tangence

# Le diagnostic

Robust SL ( $K = 2$ )



Vraie hiérarchie 2-NN




Une asymétrie : condition d'ordre  $K$  sur les **points**, mais connexité d'ordre 1 par les **arêtes**



# La réparation : le complexe de Čech et les $K$ -polyèdres

- ▶ **Graphe géométrique**  $\longrightarrow$  **complexe de Čech** :  
un  $K$ -simplexe  $\iff K + 1$  boules d'intersection non vide
- ▶ **Composantes connexes**  $\longrightarrow$   **$K$ -polyèdres** :  
des  $(K - 1)$ -simplexes recollés par des  $K$ -simplexes
- ▶ Pour  $K \geq 2$ , les amas peuvent **se recouvrir**



**Théorème [ANS 26] [EUSIPCO 24]** : à tout niveau, les  $K$ -polyèdres identifient *exactement* les amas discrets de forte densité de l'estimateur  $\hat{f}_{K\text{-NN}}$ . Pour  $K = 1$  : le *Single-Linkage*


[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

[EUSIPCO 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Benefits of hypergraphs for density-based clustering », *EUSIPCO*, Lyon, 2024.


# Qui provoque les fusions ? La condition de Gabriel

Arête de l'arbre minimum couvrant  $\longrightarrow$  simplexe  $K$ -séparant

- **Définition [ANS 26]** : un simplexe est dit  **$K$ -séparant** s'il provoque une fusion  $K$ -NN
- **Cas  $K = 1$**  : les 1-séparants sont exactement les arêtes de l'arbre minimum couvrant
- **Définition [ANS 26]** : un  $K$ -simplexe est dit de **Gabriel** si sa miniboule ne contient aucun autre point
- **Théorème [ANS 26]** : tout simplexe  $K$ -séparant est de GABRIEL



Triangle de Gabriel (boule vide)



Non-Gabriel (boule non vide)



## $K$ -arbre couvrant et mosaïque de Delaunay d'ordre $K$

- **Fusions critiques** : les simplexes  $K$ -séparants, tous  $K$ -GABRIEL (boule minimale vide)
- **Arbre couvrant**  $\longrightarrow$   **$K$ -arbre couvrant** : élagué à  $r$ , il redonne les  $K$ -polyèdres [ANS 26]
- **Delaunay**  $\longrightarrow$  **mosaïque d'ordre  $K$**  : elle porte tous les simplexes  $K$ -GABRIEL [Edelsbrunner–Osang 23]
- Pour  $K = 2$  : tout se lit dans DELAUNAY, en  $\mathcal{O}(n \log n)$  dans le plan


### Analogie ordre 1 vs. ordre $K$

|                  | $K = 1$       | $K \geq 2$           |
|------------------|---------------|----------------------|
| <b>Sommets</b>   | points        | $(K - 1)$ -simplexes |
| <b>Fusions</b>   | arêtes        | $K$ -simplexes       |
| <b>Condition</b> | arête GABRIEL | $K$ -GABRIEL         |
| <b>Domaine</b>   | DELAUNAY      | DELAUNAY d'ordre $K$ |

[Edelsbrunner–Osang 23] H. Edelsbrunner, G. Osang, « A simple algorithm for higher-order Delaunay mosaics and alpha shapes », *Algorithmica*, 2023.  
 [ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.



## Pourquoi Gabriel plutôt que la mosaïque de Delaunay d'ordre supérieur ?



- ▶ Quasi dégénérée, la sphère circonscrite admet des témoins **arbitrairement lointains** ; ceux de la *miniball* sont **localisables**
- ▶ Une décomposition en **paires bien séparées** [Callahan–Kosaraju 95] élimine alors des **blocs** de candidats **en parallèle** ; DELAUNAY reste séquentiel

[Callahan–Kosaraju 95] P. B. Callahan, S. R. Kosaraju, « A decomposition of multidimensional point sets with applications to  $k$ -nearest-neighbors and  $n$ -body potential fields », *J. ACM*, 42(1), 1995.


04

# La **percolation** comme mesure de performance





## Le phénomène au cœur de tout : la percolation continue



$$r < r_c$$


$$r = r_c$$

$$r > r_c$$

Au-delà d'un seuil critique, une **composante géante** (en rouge) émerge [Penrose 03]




## Pourquoi le *Single-Linkage* échoue en dimension $\geq 2$



Deux amas denses,  $A$  et  $B$  (les carrés), sur un fond de faible densité




## Pourquoi le *Single-Linkage* échoue en dimension $\geq 2$



Arbre couvrant élagué au rayon  $r_1$  : la percolation a lieu dans chaque carré, pas sur le fond




## Pourquoi le *Single-Linkage* échoue en dimension $\geq 2$



Au rayon  $r_2 > r_1$ , le **fond percole aussi** : A et B fusionnent *avant* d'avoir été entièrement récupérés



## La fraction récupérable




Fraction de points dans la composante géante [ANS 26]

- En abscisse : l'intensité  $\lambda$  ; en ordonnée : la fraction des points dans la **composante géante**
- Sous le seuil critique  $\lambda_c$  : rien
- La **fraction récupérable** d'un amas se lit sur la courbe



## Quantifier : la *vitesse de percolation*



$$v = \frac{\lambda_c}{\lambda_{1-\epsilon}}$$

- $\lambda_{1-\epsilon}$  : l'amas est presque **entier**
- Plus  $v$  est **proche de 1**, meilleur est l'algorithme  
[SIGMETRICS SRC 24] [CN 24]

Probabilité de percolation des  $K$ -polyèdres [ANS 26]

[SIGMETRICS SRC 24] L. Hauseux, « How can we theoretically measure the performance of density-based clustering algorithms ? », ACM SIGMETRICS SRC, Venice, 2024 (2<sup>e</sup> prix).

[CN 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Hypergraphs, percolation and hierarchical clustering », *Complex Networks & Their Applications*, Istanbul, 2024.

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.



## Vitesses de percolation mesurées

| $K$ | $p = 2$      |              |              | $p = 3$      |              |              | $p = 4$      |              |              |
|-----|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|
|     | HGP          | Robust SL    | DBSCAN       | HGP          | Robust SL    | DBSCAN       | HGP          | Robust SL    | DBSCAN       |
| 1   | <b>0,735</b> | <b>0,735</b> | <b>0,735</b> | <b>0,563</b> | <b>0,563</b> | <b>0,563</b> | <b>0,362</b> | <b>0,362</b> | <b>0,362</b> |
| 2   | <b>0,779</b> | 0,689        | 0,735        | <b>0,646</b> | 0,462        | 0,563        | <b>0,451</b> | 0,271        | 0,362        |
| 3   | <b>0,800</b> | 0,632        | 0,753        | <b>0,690</b> | 0,412        | 0,582        | <b>0,497</b> | 0,247        | 0,378        |
| 4   | <b>0,817</b> | 0,598        | 0,767        | <b>0,714</b> | 0,400        | 0,605        | <b>0,500</b> | 0,246        | 0,409        |
| 5   | <b>0,826</b> | 0,584        | 0,779        | <b>0,732</b> | 0,399        | 0,625        | <b>0,534</b> | 0,236        | 0,415        |

Mesures des vitesses de percolation [ANS 26]

- ▶  **$K$ -polyèdres** : la vitesse **croît** avec  $K$ , en dimension 2, 3 et 4
- ▶ **Robust SL** : elle **décroît** ; élaguer la frontière, c'est jeter une part de l'amas
- ▶ **DBSCAN** : il réintègre cette frontière élaguée, mais ses cœurs percolent trop tôt

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

05


# Applications : LiDAR 3D et 4D, sans apprentissage





## La hiérarchie devient un espace de résolution

- ▶ L'arbre hiérarchique n'est pas qu'une sortie : on peut y **injecter des *a priori*** géométriques
- ▶ **Détection d'anomalies 3D** : comparaison au modèle théorique du navire
- ▶ Banc d'essai sur 2 000 000 points : objets étrangers **parfaitement isolés**, sans aucun apprentissage



Modèle de référence en rouge, anomalies en couleurs  
**[AYANA RA 25]**  
© Naval Group


En collaboration avec Marie ASPRO (Inria Startup Studio)

# Panoptique 3D : l'état de l'art est un clustering

Panoptique = la *classe* de chaque point + son *instance*

- ▶ L'instance s'apprenait de bout en bout, au prix d'annotations coûteuses
- ▶ ALPINE [ALPINE 25] : une bonne sémantique, puis, classe par classe, un **clustering classique** (graphe des  $k$  plus proches voisins, seuil, **composantes connexes**)
- ▶ En 4D, Geo-4D [Geo-4D 25] garde le schéma et y ajoute une **association géométrique** entre trames, elle aussi sans apprentissage




État de l'art en segmentation panoptique sur LiDAR extérieur



[ALPINE 25] C. Sautier, G. Puy, A. Boulch, R. Marlet, V. Lepetit, « Is clustering enough for LiDAR instance segmentation ? A state-of-the-art training-free baseline » (ALPINE), 2025.  
[Geo-4D 25] G. Oh, Y. Jang, J. Choi, S.-J. Kang, G. Lin, S. Kim, « Training-free global geometric association for 4D LiDAR panoptic segmentation » (Geo-4D), 2025.



## Nos premiers résultats : 3D




*A priori* géométriques appliqués aux volumes des instances, sur SemanticKITTI [SemanticKITTI 19]

[SemanticKITTI 19] J. Behley *et al.*, « SemanticKITTI : A Dataset for Semantic Scene Understanding of LiDAR Sequences », ICCV, 2019.




## Nos premiers résultats : 4D

Vérité terrain



Notre algorithme



SemanticKITTI [SemanticKITTI 19], 200 trames

suivi par **transport optimal** + filtre de KALMAN, **sans apprentissage**

[SemanticKITTI 19] J. Behley *et al.*, « SemanticKITTI : A Dataset for Semantic Scene Understanding of LiDAR Sequences », *ICCV*, 2019.

# 06


## Vers des données davantage structurées





## Les deux idées de la thèse appliquées à des données davantage structurées

- 1) les interactions d'ordre supérieur apportent la robustesse
- 2) la percolation gouverne les performances




trait plein : attraction      pointillés : répulsion

trait gras : arête satisfaite (trait fin : non satisfaite)

## Graphes signés : les liens *créent* les communautés

**[Asilomar 25]**



**Images** : extraire des réseaux de fissures [EUVIP 26]

© Cerema


**[Asilomar 25]** L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs », Asilomar, 2025.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.



# Détection de communautés sur graphes signés : un cadre bayésien

Détection de communautés [Avrachenkov–Dreveton 22] : retrouver les communautés cachées  $\Sigma$  d'un graphe dont les liens sont *signés*



- ▶  $W_e > 0$  encode une **attraction** ;  $W_e < 0$ , une **répulsion** ;  $|W_e|$  mesure la force de l'interaction
- ▶ Dans le cas étudié, le canal calibré donne une loi *a posteriori* de GIBBS signée [I&I 26+] :


$$U(\sigma) = -\log \mu_0(\sigma \mid X) + \sum_{\substack{e=\{i,j\} \\ W_e > 0}} W_e \mathbb{I}_{\{\sigma_i \neq \sigma_j\}} + \sum_{\substack{e=\{i,j\} \\ W_e < 0}} |W_e| \mathbb{I}_{\{\sigma_i = \sigma_j\}}, \quad \mu(\sigma) = \frac{e^{-U(\sigma)}}{Z}$$

[Avrachenkov–Dreveton 22] K. Avrachenkov, M. Dreveton, *Statistical Analysis of Networks*, Now Publishers, 2022.

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.



## Un pas de Swendsen–Wang signé



$$\mathbb{P}(e \text{ gelée} \mid \sigma) = \begin{cases} 1 - e^{-|W_e|}, & e \text{ satisfaite} \\ 0, & e \text{ non satisfaite} \end{cases}$$

- Pour deux classes et un *a priori* uniforme, chaque composante gelée est **retournée en bloc** avec probabilité 1/2 : la transition est réversible et préserve  $\mu$  [Swendsen–Wang 87]
- Dans la preuve, un pas depuis  $\Sigma$  produit une **réplique couplée de la loi *a posteriori***  $\Sigma^{(1)}$

[Swendsen–Wang 87] R. H. Swendsen, J.-S. Wang, « Nonuniversal critical dynamics in Monte Carlo simulations », *Physical Review Letters*, 1987.







# Généraliser Swendsen–Wang aux interactions d'ordre supérieur

$$U(\sigma) = U_0(\sigma) + \sum_{b \in \mathcal{B}} U_b(\sigma), \quad b = \text{arête, triangle, clique...}$$

Triangle **attractif**  
tout ou rien



Triangle **répulsif** (frustré)  
jamais les deux arêtes




► Un seul tirage par motif : on introduit de la **corrélation** dans le processus de gel [Asilomar 25] [I&I 26+]

[Asilomar 25] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs », Asilomar, 2025.

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.




# La percolation borne le recouvrement des communautés




[Sankararaman–Bacelli 18] A. Sankararaman, F. Bacelli, « Community detection on Euclidean random graphs », *ACM–SIAM SODA*, 2018.

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.


## Extraction de réseaux de fissures sur images




intensité



profondeur



similarité d'arête



squelette extrait

- ▶ Du **pixel** (filtre de FRANGI [Frangi 98], qui juge chaque pixel seul et se fragmente sous le bruit) à la **paire de pixels** (graphe de FRANGI [GRETSI 25])
- ▶ **Multimodal** au niveau de l'**opérateur** : on somme les hessiennes normalisées, jamais les réponses [EUVIP 26]
- ▶ Transferts exploratoires sans réentraînement ; sortie sous forme de **graphe éditable**

[Frangi 98] A. F. Frangi, W. J. Niessen, K. L. Vincken, M. A. Viergever, « Multiscale vessel enhancement filtering », MICCAI, 1998.


[GRETSI 25] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Généralisation du filtre de Frangi pour l'extraction des réseaux de fissures », GRETSI, 2025.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.



## La hessienne : l'information sur les structures *tubulaires*

$\mathcal{H}_\sigma(x) = \nabla^2(G_\sigma * I)(x)$ , symétrique réelle : axes propres  $e_1, e_2$ , demi-axes  $1/\sqrt{|\lambda_1|}$  et  $1/\sqrt{|\lambda_2|}$



Le filtre de FRANGI [Frangi 98] en tire **deux** nombres :

- $R_B = \frac{|\lambda_1|}{|\lambda_2|}$  : la **forme**  
0 pour une crête très allongée, 1 pour un disque
- $S = \sqrt{\lambda_1^2 + \lambda_2^2}$  : le **contraste**  
la force des courbures


$$\exp\left(-\frac{R_B^2}{2\beta^2}\right) \left(1 - \exp\left(-\frac{S^2}{2c^2}\right)\right) \quad \text{si } \lambda_2 > 0, \quad 0 \text{ sinon}$$

la réponse de FRANGI : une crête sombre et contrastée



## Ce que le graphe ajoute : l'*alignement*


Le filtre juge chaque pixel **seul** ; le graphe demande que les directions  $e_1$  des **deux** pixels concordent



$$S_{\text{align}} = \exp \left[ -\frac{1}{2} \left( \frac{\sin(\theta(x_i) - \theta(x_j))}{s_a} \right)^2 \right]$$

le sinus, car  $\theta$  et  $\theta + \pi$  décrivent le même axe **[GRETSI 25] [EUVIP 26]**

## Un fond granulaire : l'ordre 2 coupe les ponts parasites



visible granulaire

réponse de FRANGI au pixel

similarité de FRANGI

composante retenue en bleu

- ▶ Chaque caillou porte une réponse : le fond est aussi « crête » que la fissure
- ▶ Une **chaîne d'arêtes** suffit alors à relier les cailloux de proche en proche : le fond percole
- ▶ À l'**ordre 2**, deux arêtes ne se recollent que par un **triangle** : une chaîne sans triangle ne propage plus la connexité, et la vitesse de percolation croît avec  $K$  [ANS 26] : d'où le choix  $K = 2$  [EUVIP 26]

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.

07

# Perspectives : la voie hiérarchique






## Retour au début : le théorème d'impossibilité de Kleinberg

Une fonction de clustering  $\mathcal{C}$  associe à un espace métrique fini  $(\mathcal{X}, d)$  une **partition** de  $\mathcal{X}$

- (i) **Invariance d'échelle** :  $\mathcal{C}(\mathcal{X}, \lambda d) = \mathcal{C}(\mathcal{X}, d)$
- (ii) **Richesse** : toute partition est atteinte
- (iii) **Cohérence** : resserrer un amas rendu par  $\mathcal{C}$ , ou écarter deux de ces amas, ne change rien

**Impossibilité [Kleinberg 02]** : aucune  $\mathcal{C}$  ne satisfait les trois



compatibles deux à deux,  
jamais trois à trois






## Retour au début : le théorème d'impossibilité de Kleinberg

Une fonction de clustering  $\mathcal{C}$  associe à un espace métrique fini  $(\mathcal{X}, d)$  une **partition** de  $\mathcal{X}$

- (i) **Invariance d'échelle** :  $\mathcal{C}(\mathcal{X}, \lambda d) = \mathcal{C}(\mathcal{X}, d)$
- (ii) **Richesse** : toute partition est atteinte
- (iii) **Cohérence** : resserrer un amas rendu par  $\mathcal{C}$ , ou écarter deux de ces amas, ne change rien



compatibles deux à deux,  
jamais trois à trois

**Impossibilité [Kleinberg 02]** : aucune  $\mathcal{C}$  ne satisfait les trois


CARLSSON & MÉMOLI ont trouvé la solution, et elle est **hiérarchique** : c'est le **Single-Linkage [Carlsson-Mémoli 10]**



## Une dynamique de clusters **hiérarchique**

$\xi_e \sim \text{Exp}(|W_e|)$  si  $e$  est satisfaite,  $\xi_e = +\infty$  sinon ;

$\Pi_\beta =$  composantes connexes du graphe  $(V, \{e : \xi_e \leq \beta\})$ ,  $0 \leq \beta \leq 1$



- En coupant aux **feuilles**, on retrouve GLAUBER ; en coupant aux **racines**, SWENDSEN-WANG
- La coupe la plus prometteuse pour le **recouvrement faible** : la **température de percolation** [I&I 26+]

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.



# Les modèles de fondation : le texte, et désormais l'image



- ▶ Entraîné **une seule fois**, sur des données massives et **sans annotation** [Bommasani 21]
- ▶ **Réutilisable** : un même socle sert quantité de tâches différentes
- ▶ Il en **émerge** des capacités que personne n'a programmées
- ▶ Tout le monde part du **même socle**


[Bommasani 21] R. Bommasani *et al.*, « On the opportunities and risks of foundation models », 2021.

[GPT-3 20] T. Brown *et al.*, « Language models are few-shot learners », *NeurIPS*, 2020.

[SAM 23] A. Kirillov *et al.*, « Segment Anything », *ICCV*, 2023.



## L'adapter sans le réentraîner : *LoRA*




- ▶ On gèle le tronc pré-entraîné, on n'apprend qu'une correction de **petit rang**  $W = W_0 + BA$  [LoRA 22]
- ▶ CrackSAM [CrackSAM 24] : 4,4 M de poids appris sur les 637 M de SAM
- ▶ SAM a déjà tout vu : lui donner en plus nos descripteurs (hessienne, gradient) ne change **rien**
- ▶ Et il **transfère** : des fissures de chantiers jamais vus, sans rien réapprendre

[LoRA 22] E. J. Hu et al., « LoRA : low-rank adaptation of large language models », *ICLR*, 2022.

[CrackSAM 24] K. Ge et al., « Fine-tuning vision foundation model for crack segmentation in civil infrastructures », *Construction and Building Materials*, 2024.



## Comment guider l'attention *via* la hiérarchie ? Une idée à explorer



- ▶ L'**attention** : chaque jeton pose une **requête**, la compare aux **clefs** de tous les autres, et repart avec la moyenne de leurs **valeurs**, pondérée par un **score visuel** que SAM sait déjà calculer
- ▶ On y **ajoute un bonus** avant le *softmax* : un échange **favorisé**, jamais imposé [Graphormer 21]
- ▶ Le bonus vient de la **hiérarchie** du graphe de FRANGI : plus deux jetons **fusionnent tôt** dans l'arbre, plus il est fort, même loin dans l'image [EUVIP 26] ; LoRA l'apprend avec un **seul** coefficient  $\beta$  [LoRA 22]

$$\text{attention} = \text{softmax}(\text{scores visuels} + \beta B_H)$$


[Graphormer 21] C. Ying *et al.*, « Do Transformers really perform badly for graph representation ? », *NeurIPS*, 2021.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », *EUVIP*, 2026.

[LoRA 22] E. J. Hu *et al.*, « LoRA : low-rank adaptation of large language models », *ICLR*, 2022.



# Vers un modèle de fondation pour la 3D ?




en 3D, l'unité de calcul reste celle de l'échantillonnage :  
point du capteur ou case de grille

[GPT-3 20] T. Brown *et al.*, « Language models are few-shot learners », *NeurIPS*, 2020.


[SAM 23] A. Kirillov *et al.*, « Segment Anything », *ICCV*, 2023.

## La raison de fond : le nuage est un *artefact du capteur*



- ▶ La **densité** décroît avec la portée ; s'y ajoutent les nappes de balayage et les **occultations**
- ▶ Un modèle point par point apprend donc *en même temps* la géométrie, le capteur, la densité, l'occultation **et** la sémantique
- ▶ Hypothèse : c'est *une* raison centrale de la difficulté

## Remplacer les points par une hiérarchie de **polyèdres** ?



- Même recette que pour le texte : le **polyèdre** est l'**alphabet** (l'unité, fixée une fois pour toutes) et la **hiérarchie** en est la **grammaire**



# 08

## Conclusion





## Deux fils conducteurs, quatre contributions

1) Quand les relations binaires sont insuffisantes ou instables,  
les **interactions d'ordre supérieur** apportent une cohérence robuste.

2) La **percolation** est la clef de voûte théorique  
pour quantifier les performances de ces algorithmes

- Une **vue unifiée** du *Single-Linkage* : heuristique, géométrique, statistique **[ANS 26]** ; LiDAR 3D et 4D sans apprentissage
- **HGP-Clusterer** : la hiérarchie  $K$ -NN exacte, via Čech, GABRIEL et DELAUNAY d'ordre  $K$  **[EUSIPCO 24] [CN 24] [ANS 26]**
- La **vitesse de percolation** : elle explique l'échec de Robust SL et (H)DBSCAN, et les gains des  $K$ -polyèdres **[SIGMETRICS SRC 24]**
- L'**export du paradigme** : graphes signés **[Asilomar 25] [I&I 26+]** ; imagerie, graphe de FRANGI multimodal **[GRETSI 25] [EUVIP 26] [ISPRS 26+]**

**[EUSIPCO 24]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Benefits of hypergraphs for density-based clustering », *EUSIPCO*, Lyon, 2024.

**[CN 24]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Hypergraphs, percolation and hierarchical clustering », *Complex Networks & Their Applications*, Istanbul, 2024.

**[ANS 26]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

**[SIGMETRICS SRC 24]** L. Hauseux, « How can we theoretically measure the performance of density-based clustering algorithms ? », *ACM SIGMETRICS SRC*, Venice, 2024 (2<sup>e</sup> prix).

**[Asilomar 25]** L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs », *Asilomar*, 2025.

**[I&I 26+]** L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.

**[GRETSI 25]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Généralisation du filtre de Frangi pour l'extraction des réseaux de fissures », *GRETSI*, 2025.

**[EUVIP 26]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », *EUVIP*, 2026.

**[ISPRS 26+]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, article en préparation pour l'*ISPRS Journal of Photogrammetry and Remote Sensing*, 2026.



## Autres perspectives

- ▶ **La grande dimension** : une **réduction de dimension** d'ordre supérieur, là où les méthodes courantes s'appuient sur des graphes de voisinage (UMAP)
- ▶ **Question ouverte** : HGP-Clusterer n'est que *fractionnellement* consistant ; un algorithme consistant en dimension  $p \geq 2$  reste à inventer

# Publications

## Journal

- ▶ **[ANS 26]** *Generalization of Single-Linkage with higher-order interactions*, *Applied Network Science*, 2026

## Conférences internationales et nationales

- ▶ **[CN 23]** Filaments de galaxies, Complex Networks, Menton, 2023
- ▶ **[EUSIPCO 24]** Hypergraphes pour le *clustering* par densité, EUSIPCO, Lyon, 2024
- ▶ **[CN 24]** Hypergraphes, percolation et *clustering* hiérarchique, Complex Networks, Istanbul, 2024
- ▶ **[SIGMETRICS SRC 24]** Mesure théorique de performance, ACM SIGMETRICS SRC, Venise, 2024 (**2<sup>e</sup> prix**)
- ▶ **[Asilomar 25]** Dynamiques d'amas d'ordre supérieur, Asilomar, 2025
- ▶ **[GRETSI 25]** Généralisation du filtre de Frangi, GRETSI, Strasbourg, 2025
- ▶ **[EUVIP 26]** Extraction multimodale de fissures sans apprentissage, EUVIP, Luxembourg, 2026

## En cours

- ▶ **[I&I 26+]** Cadre bayésien pour la détection de communautés sur graphes signés (journal)
- ▶ **[ISPRS 26+]** Graphe de Frangi généralisé, multimodal et sans apprentissage (journal ISPRS)

**Logiciels** *Open source* : dépôts GitHub Ayana-Inria/HypergraphPercol\_K2 et Ayana-Inria/Frangi-EUVIP

*Merci.*





## Travaux de l'auteur présentés aujourd'hui

- ▶ **[HAL 17]** L. Hauseux (encadré par B. Błaszczyszyn), « Un classificateur non supervisé utilisant les complexes simpliciaux », Inria Paris, 2017. HAL : hal-01597846.
- ▶ **[CN 23]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Graph based approach for galaxy filament extraction », *Complex Networks & Their Applications*, Menton, 2023.
- ▶ **[EUSIPCO 24]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Benefits of hypergraphs for density-based clustering », *EUSIPCO*, Lyon, 2024.
- ▶ **[CN 24]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Hypergraphs, percolation and hierarchical clustering », *Complex Networks & Their Applications*, Istanbul, 2024.
- ▶ **[SIGMETRICS SRC 24]** L. Hauseux, « How can we theoretically measure the performance of density-based clustering algorithms ? », ACM SIGMETRICS SRC, Venise, 2024 (2<sup>e</sup> prix).
- ▶ **[ANS 26]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.
- ▶ **[GRETSI 25]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Généralisation du filtre de Frangi pour l'extraction des réseaux de fissures », GRETSI, 2025.
- ▶ **[Asilomar 25]** L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs », Asilomar, 2025.
- ▶ **[EUVIP 26]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.
- ▶ **[I&I 26+]** L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.
- ▶ **[ISPRS 26+]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, article en préparation pour l'*ISPRS Journal of Photogrammetry and Remote Sensing*, 2026.



## Bibliographie (1/4)

- ▶ [Cameron–Martin 44] R. H. Cameron, W. T. Martin, « Transformations of Wiener integrals under translations », *Annals of Mathematics*, 45(2), 1944.
- ▶ [Florek 51] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, S. Zubrzycki, « Sur la liaison et la division des points d'un ensemble fini », *Colloq. Math.*, 1951.
- ▶ [Schilder 66] M. Schilder, « Some asymptotic formulas for Wiener integrals », *Transactions of the AMS*, 125(1), 1966.
- ▶ [Gower–Ross 69] J. C. Gower, G. J. S. Ross, « Minimum spanning trees and Single-Linkage cluster analysis », *JRSS C*, 1969.
- ▶ [Hartigan 81] J. A. Hartigan, « Consistency of Single Linkage for high-density clusters », *JASA*, 1981.
- ▶ [Forina 83] M. Forina, C. Armanino, S. Lanteri, E. Tiscornia, « Classification of olive oils from their fatty acid composition », 1983 (jeu de données).
- ▶ [Swendsen–Wang 87] R. H. Swendsen, J.-S. Wang, « Nonuniversal critical dynamics in Monte Carlo simulations », *Physical Review Letters*, 1987.
- ▶ [Edwards–Sokal 88] R. G. Edwards, A. D. Sokal, « Generalization of the Fortuin–Kasteleyn–Swendsen–Wang representation and Monte Carlo algorithm », *Physical Review D*, 38(6), 1988.
- ▶ [Ester 96] M. Ester, H.-P. Kriegel, J. Sander, X. Xu, « A density-based algorithm for discovering clusters » (DBSCAN), *KDD*, 1996.
- ▶ [Meester–Roy 96] R. Meester, R. Roy, *Continuum Percolation*, Cambridge Tracts in Mathematics 119, Cambridge University Press, 1996.



## Bibliographie (2/4)

- ▶ [Frangi 98] A. F. Frangi, W. J. Niessen, K. L. Vincken, M. A. Viergever, « Multiscale vessel enhancement filtering », MICCAI, 1998.
- ▶ [Kleinberg 02] J. Kleinberg, « An impossibility theorem for clustering », *Advances in Neural Information Processing Systems (NIPS)*, vol. 15, MIT Press, p. 446–453, 2002.
- ▶ [Penrose 03] M. Penrose, *Random Geometric Graphs*, Oxford University Press, 2003.
- ▶ [Berlinet–Thomas–Agnan 04] A. Berlinet, C. Thomas-Agnan, *Reproducing Kernel Hilbert Spaces in Probability and Statistics*, Kluwer, 2004.
- ▶ [Ghrist 08] R. Ghrist, « Barcodes : the persistent topology of data », Bulletin of the AMS, 2008.
- ▶ [MALIS 09] S. C. Turaga, K. L. Briggman, M. Helmstaedter, W. Denk, H. S. Seung, « Maximin affinity learning of image segmentation », *NIPS*, 2009.
- ▶ [Chaudhuri–Dasgupta 10] K. Chaudhuri, S. Dasgupta, « Rates of convergence for the cluster tree », *Advances in Neural Information Processing Systems (NIPS)*, vol. 23, p. 343–351, 2010.
- ▶ [Carlsson–Mémoli 10] G. Carlsson, F. Mémoli, « Characterization, stability and convergence of hierarchical clustering methods », *JMLR*, 2010.
- ▶ [Dembo–Zeitouni 10] A. Dembo, O. Zeitouni, *Large Deviations Techniques and Applications*, 2<sup>e</sup> éd., Springer, 2010.
- ▶ [Campello 13] R. Campello, D. Moulavi, J. Sander, « Density-based clustering based on hierarchical density estimates » (HDBSCAN), *PAKDD*, 2013.
- ▶ [ToMATo 13] F. Chazal, L. J. Guibas, S. Y. Oudot, P. Skraba, « Persistence-based clustering in Riemannian manifolds » (ToMATo), *J. ACM*, 60(6), art. 41, 2013.





## Bibliographie (3/4)

- ▶ [Biau–Devroye 15] G. Biau, L. Devroye, *Lectures on the Nearest Neighbor Method*, Springer, 2015.
- ▶ [Boissonnat 18] J.-D. Boissonnat, F. Chazal, M. Yvinec, *Geometric and Topological Inference*, Cambridge University Press, 2018.
- ▶ [Sankararaman–Baccelli 18] A. Sankararaman, F. Baccelli, « Community detection on Euclidean random graphs », *ACM–SIAM SODA*, 2018.
- ▶ [SemanticKITTI 19] J. Behley *et al.*, « SemanticKITTI : A Dataset for Semantic Scene Understanding of LiDAR Sequences », *ICCV*, 2019.
- ▶ [GPT-3 20] T. Brown *et al.*, « Language models are few-shot learners », *NeurIPS*, 2020.
- ▶ [Bommasani 21] R. Bommasani *et al.*, « On the opportunities and risks of foundation models », 2021.
- ▶ [Graphormer 21] C. Ying *et al.*, « Do Transformers really perform badly for graph representation ? », *NeurIPS*, 2021.
- ▶ [Avrachenkov–Dreveton 22] K. Avrachenkov, M. Dreveton, *Statistical Analysis of Networks*, Now Publishers, 2022.
- ▶ [LoRA 22] E. J. Hu *et al.*, « LoRA : low-rank adaptation of large language models », *ICLR*, 2022.
- ▶ [SAM 23] A. Kirillov *et al.*, « Segment Anything », *ICCV*, 2023.



## Bibliographie (4/4)


- ▶ [Edelsbrunner–Osang 23] H. Edelsbrunner, G. Osang, « A simple algorithm for higher-order Delaunay mosaics and alpha shapes », *Algorithmica*, 2023.
- ▶ [Rolle–Scoccola 24] A. Rolle, L. Scoccola, « Stable and consistent density-based clustering via multiparameter persistence » (Persistable), *JMLR*, 25(258), 2024.
- ▶ [CrackSAM 24] K. Ge *et al.*, « Fine-tuning vision foundation model for crack segmentation in civil infrastructures », *Construction and Building Materials*, 2024.
- ▶ [SAM 2 24] N. Ravi *et al.*, « SAM 2 : segment anything in images and videos », 2024.
- ▶ [AYANA RA 25] Équipe-projet AYANA, « 3D LiDAR Instance Segmentation with Geometric Priors : The HGP-Clusterer », *Rapport annuel d'activité Inria 2025*, § 7.7.
- ▶ [ALPINE 25] C. Sautier, G. Puy, A. Boulch, R. Marlet, V. Lepetit, « Is clustering enough for LiDAR instance segmentation ? A state-of-the-art training-free baseline » (ALPINE), 2025.
- ▶ [Geo-4D 25] G. Oh, Y. Jang, J. Choi, S.-J. Kang, G. Lin, S. Kim, « Training-free global geometric association for 4D LiDAR panoptic segmentation » (Geo-4D), 2025.
- ▶ [Sonata 25] X. Wu *et al.*, « Sonata : self-supervised learning of reliable point representations », *CVPR*, 2025.
- ▶ [Concerto 25] Y. Zhang *et al.*, « Concerto : joint 2D–3D self-supervised learning emerges spatial representations », *NeurIPS*, 2025.
- ▶ [Utonia 26] Y. Zhang *et al.*, « Utonia : toward one encoder for all point clouds », 2026.

# Diapositives de secours






## Stylométrie 2017 : le cas à 5 auteurs




- ▶ 5 auteurs  $\times$  40 textes ( $P = 70\%$ ,  $k = 5$ )
- ▶ 4 classes correctement identifiées...
- ▶ ... mais la 4<sup>e</sup> (textes 120–159) est manquée
- ▶ Ronds noirs : non classés ; étoiles : affectés à plusieurs classes




## Banc d'essai SIPU : toutes choses égales par ailleurs



Même  $\text{min\_cluster\_size} = \sqrt{n}$ , même excès de masse :  
la seule différence est la **connexité triangulaire**




| Jeu    | HDBSCAN | 2-polyèdres  |
|--------|---------|--------------|
| a2     | 0,762   | <b>0,834</b> |
| a3     | 0,696   | <b>0,831</b> |
| d31    | 0,660   | <b>0,835</b> |
| s2     | 0,780   | <b>0,842</b> |
| s3     | 0,251   | <b>0,418</b> |
| birch2 | 0,996   | <b>0,998</b> |




ARI ; grille : vérité, HDBSCAN, notre algorithme



## En pratique ( $K = 2$ ) : les huiles d'olive italiennes [Forina 83]



HDBSCAN : 3 macrorégions



2-polyèdres : **8 provinces identifiées**  
parmi les 72 % de points classés

Au-delà de l'état de l'art [Rolle–Scoccola 24] [ANS 26]

[Forina 83] M. Forina, C. Armanino, S. Lanteri, E. Tiscornia, « Classification of olive oils from their fatty acid composition », 1983 (jeu de données).

[Rolle–Scoccola 24] A. Rolle, L. Scoccola, « Stable and consistent density-based clustering via multiparameter persistence » (Persistable), *JMLR*, 25(258), 2024.

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.




## Huiles d'olive : la matrice de confusion

| Pers./Ours | 1     | 2    | 3       | 4 | 5     | 6     | 7     | 8     | 9     | Miss.  |
|------------|-------|------|---------|---|-------|-------|-------|-------|-------|--------|
| N. Apulia  | 12/24 | 0/0  | 0/0     | - | 0/0   | 0/0   | 0/0   | 0/0   | 0/0   | 13/1   |
| Calabria   | 0/0   | 7/25 | 1/2     | - | 0/0   | 0/0   | 0/0   | 0/0   | 0/0   | 48/29  |
| S. Apulia  | 0/0   | 0/0  | 100/145 | - | 0/0   | 0/0   | 0/0   | 0/0   | 0/0   | 106/61 |
| Sicilia    | 3/6   | 0/1  | 0/2     | - | 0/0   | 0/0   | 0/0   | 0/0   | 0/0   | 33/27  |
| Inl. Sard. | 0/0   | 0/0  | 0/0     | - | 51/62 | 0/0   | 0/0   | 0/0   | 0/0   | 14/3   |
| Coast S.   | 0/0   | 0/0  | 0/0     | - | 0/2   | 19/29 | 0/0   | 0/0   | 0/0   | 14/2   |
| E. Ligur.  | 0/0   | 0/0  | 0/0     | - | 0/0   | 0/0   | 14/32 | 1/2   | 0/1   | 35/15  |
| W. Ligur.  | 0/0   | 0/0  | 0/0     | - | 0/0   | 0/0   | 0/0   | 29/33 | 0/0   | 21/17  |
| Umbria     | 0/0   | 0/0  | 0/0     | - | 0/0   | 0/0   | 0/0   | 0/0   | 42/46 | 9/5    |


- ▶ 412/572 points classés (72 %), dont 96,1 % correctement
- ▶ Persistable [Rolle–Scoccola 24] : 49 % classés seulement
- ▶ En partition exhaustive : ARI 0,890 contre 0,848



## Vitesses de percolation : *Robust Single-Linkage* et DBSCAN



*Robust SL* : la percolation converge trop lentement vers 1



DBSCAN : frontière réintégrée, mais les cœurs percolent trop tôt

$n = 100\,000$  points uniformes, 100 tirages ;  $\hat{v} = \hat{\lambda}_\varepsilon / \hat{\lambda}_{1-\varepsilon}$ ,  $\varepsilon = 3\%$  ; repère 2D,  $K = 1$  :  $\lambda_c \approx 1,44$





## Quand $K \rightarrow +\infty$ : la fenêtre gaussienne



- ▶ Dans la fenêtre  $\mu = K + a\sqrt{K}$ , les niveaux  $K$ -NN convergent vers les **excursions**  $E_a = \{G_p \geq -a\}$  d'un champ gaussien
- ▶ Covariance du champ : le volume d'intersection de deux boules
- ▶ Les trois algorithmes ne diffèrent que par l'**ordre des opérations** : dilater puis connecter (cœurs, DBSCAN) vs. connecter puis dilater (polyèdres)
- ▶ Seuils de bruit :  $a_c^{\text{poly}} \geq a_c^{\text{core}}$ , vitesse asymptotiquement meilleure pour les  $K$ -polyèdres



# Schilder dans l'espace de Cameron–Martin

L'espace de CAMERON–MARTIN  $\mathcal{H}_p$  [Cameron–Martin 44] : les déformations  $h$  du champ  $G_p$  d'énergie finie  $\|h\|_{\mathcal{H}_p}^2$  — le RKHS de sa covariance [Berlinet–Thomas-Agnan 04]

$$\text{SCHILDER [Schilder 66]} : \quad \mathbb{P}(G_p \approx a h) \approx \exp\left(-\frac{a^2}{2} \|h\|_{\mathcal{H}_p}^2\right)$$



Un point qui plonge coûte 1 ; la boule entière coûte  $1/U_p$ , l'inverse de sa **capacité** ( $1/U_2 \approx 3,4$ )

Ébauche : la borne globale (lemme de Peierls) reste à écrire

[Cameron–Martin 44] R. H. Cameron, W. T. Martin, « Transformations of Wiener integrals under translations », *Annals of Mathematics*, 45(2), 1944.

[Berlinet–Thomas-Agnan 04] A. Berlinet, C. Thomas-Agnan, *Reproducing Kernel Hilbert Spaces in Probability and Statistics*, Kluwer, 2004.

[Schilder 66] M. Schilder, « Some asymptotic formulas for Wiener integrals », *Transactions of the AMS*, 125(1), 1966.



## Le théorème de Schilder, énoncé

$G_p$  : le champ gaussien limite, centré, de covariance  $\rho_p(x - y) = |B(x, \frac{1}{2}) \cap B(y, \frac{1}{2})| / |B(0, \frac{1}{2})|$ , à trajectoires continues sur un compact  $\Gamma \subset \mathbb{R}^p$ ;  $\mathcal{H}_p$  son espace de CAMERON–MARTIN, de norme  $\|\cdot\|_{\mathcal{H}_p}$

**Théorème** (SCHILDER [Schilder 66]; forme gaussienne [Dembo–Zeitouni 10]). Pour tout borélien  $A \subseteq \mathcal{C}(\Gamma, \mathbb{R})$ , d'intérieur  $\overset{\circ}{A}$  et d'adhérence  $\overline{A}$ , quand  $a \rightarrow +\infty$  :

$$\liminf_{a \rightarrow +\infty} \frac{1}{a^2} \log \mathbb{P}(G_p \in aA) \geq - \inf_{h \in \overset{\circ}{A}} \frac{1}{2} \|h\|_{\mathcal{H}_p}^2,$$

$$\limsup_{a \rightarrow +\infty} \frac{1}{a^2} \log \mathbb{P}(G_p \in aA) \leq - \inf_{h \in \overline{A}} \frac{1}{2} \|h\|_{\mathcal{H}_p}^2.$$

- Autrement dit :  $\{G_p/a\}_{a>0}$  satisfait un **principe de grandes déviations** de vitesse  $a^2$  et de fonction de taux  $I(h) = \frac{1}{2} \|h\|_{\mathcal{H}_p}^2$ , valant  $+\infty$  hors de  $\mathcal{H}_p$

[Schilder 66] M. Schilder, « Some asymptotic formulas for Wiener integrals », *Transactions of the AMS*, 125(1), 1966.

[Dembo–Zeitouni 10] A. Dembo, O. Zeitouni, *Large Deviations Techniques and Applications*, 2<sup>e</sup> éd., Springer, 2010.



# La hiérarchie Swendsen–Wang coupée à $\beta$ , vue par Edwards–Sokal

EDWARDS–SOKAL [Edwards–Sokal 88] : tirer le couple  $(\sigma, \omega)$  plutôt que  $\sigma$  seul,  $\omega$  étant l'ensemble des arêtes gelées avant la date  $\beta$

$$\nu_\beta(\sigma, \omega) \propto \underbrace{\mu_0(\sigma) e^{-(1-\beta)U(\sigma)}}_{a \text{ priori chargé de l'énergie résiduelle}} \prod_{e \in \omega} (1 - e^{-\beta|W_e|}) \mathbb{I}_{\{e \text{ satisfaite}\}} \prod_{e \notin \omega} e^{-\beta|W_e|}$$

- **Marginale en  $\sigma$**  : sommer sur  $\omega$  donne  $e^{-\beta U(\sigma)}$  ; le poids  $(1 - \beta)U$  mis dans l'*a priori* complète l'exposant :  $\mu(\sigma) \propto \mu_0(\sigma) e^{-U(\sigma)}$  pour tout  $\beta$
- **Sachant  $\sigma$ , le gel** : arête satisfaite gelée avec probabilité  $1 - e^{-\beta|W_e|} = \mathbb{P}(\xi_e \leq \beta)$  :  $\omega = \{\xi_e \leq \beta\}$ , ses amas sont  $\Pi_\beta$ , et les mêmes horloges servent à tous les  $\beta$  (emboîtement)
- **Sachant  $\omega$ , le recoloriage** : chaque amas est retourné en bloc ou non, selon  $\mu_0(\sigma) e^{-(1-\beta)U(\sigma)}$  : les amas de  $\Pi_\beta$  interagissent encore par les arêtes non gelées ; à  $\beta = 1$ , retournements uniformes et indépendants (SWENDSEN–WANG)
- Au nœud  $u$  du dendrogramme, la coupe  $E_u$  est vue à sa date de fusion  $\beta_u$  : le facteur  $e^{(1-\beta_u)\Lambda_u(\sigma)}$  du retournement exact est ce poids résiduel [I&I 26+]

[Edwards–Sokal 88] R. G. Edwards, A. D. Sokal, « Generalization of the Fortuin–Kasteleyn–Swendsen–Wang representation and Monte Carlo algorithm », *Physical Review D*, 38(6), 1988.

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.



## Retourner un amas : la loi exacte

Un tirage d'horloges fixe le dendrogramme  $D$  ; reste à décider, à chaque fusion, **quels amas retourner**

$$\nu(\sigma \mid D) \propto \mu_0(\sigma) \prod_u \Lambda_u(\sigma) e^{(1-\beta_u) \Lambda_u(\sigma)}$$

$$\Lambda_u(\sigma) = \sum_{e \in E_u} |W_e| \mathbb{I}_{\{e \text{ satisfaite}\}} \quad (\text{poids satisfait de la coupe}) \quad \beta_u = \min_{e \in E_u, e \text{ satisfaite}} \xi_e \quad (\text{date de la fusion})$$

Au nœud  $u$ , où  $C = C_1 \sqcup C_2$  : **un seul tirage à quatre états**  $\sigma^{ab}$ , et non deux retournements indépendants


$$p_u(a, b \mid \sigma, D) = \frac{q_u^{ab}}{\sum_{c,d \in \{0,1\}} q_u^{cd}}, \quad q_u^{ab} = \mu_0(\sigma^{ab}) \prod_{v \succeq u} \Lambda_v(\sigma^{ab}) e^{(1-\beta_v) \Lambda_v(\sigma^{ab})}$$

► Seuls  $u$  et ses **ancêtres** se recalculent ; bain thermique exact, donc **balance détaillée** et  $\mu$  invariante

[I&I 26+]

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.

## Quelle coupe choisir ? Celle où les amas **percolent**




densité d'arêtes ouvertes avant  $\beta$  :  $q_p(\beta) = p(1 - e^{-u_p\beta})$ ,  $u_p = \log \frac{p}{1-p}$  ;  
**coupe critique**  $\beta_c$  :  $q_p(\beta_c) = q_c$ , le seuil de percolation du réseau

- ▶ Seule une masse **macroscopique** transporte de l'information : c'est ce que dit la borne de recouvrement de la partie précédente, évaluée à l'horizon  $\beta = 1$
- ▶ Sur la grille triangulaire, au seuil de percolation de l'*information*, le temps informationnel et  $\beta_c$  **coïncident** [I&I 26+] : le meilleur argument dont nous disposons pour dire que c'est la bonne coupe
- ▶ **Statut : un programme.** Notre meilleure borne rigoureuse vient d'une *autre* source (un canal d'information à plusieurs états sur les triangles) et *pas* de cette dynamique

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article en cours de rédaction pour *Information and Inference*, 2026.




# L'échelle des seuils du GSBM triangulaire



- Gel SW  $0,6736 < \text{triangles } 0,7192 < \text{percolation de l'information } 0,7947 < \text{record rigoureux } 0,8094$
- Point multicritique de Nishimori  $0,8358$  : conjecture



# Calibration exacte sur le SBM




- ▶ Deux répliques, deux dendrogrammes **indépendants**, coupés au même  $\beta_c$
- ▶ Chaque branche transmet exactement  $\theta^2$  : la densité d'évolution répliquée redonne  $d\theta^2 = 1$   
(le seuil de KESTEN-STIGUM, identité valable pour **toute** coupe exactement marginalisée : elle calibre le décompte, elle ne désigne pas  $\beta_c$ )
- ▶ Quand le signal diverge,  $\beta_{c,n} \rightarrow 0$  : la coupe s'écrase d'elle-même sur GLAUBER






## Validation à $10^6$ nœuds : les trois régimes



$p = 0,70$  : seules les arêtes standard percolent ; l'*overlap* reste au bruit




## Validation à $10^6$ nœuds : les trois régimes



$p = 0,72$  : toutes les dynamiques percolent... mais l'*overlap* reste au bruit (nécessaire  $\neq$  suffisant)




## Validation à $10^6$ nœuds : les trois régimes



$p = 0,80$  : composantes géantes stables et **recouvrement effectif**

## De la similarité au squelette : la chaîne d'extraction



- ▶ **Seuiller** les arêtes puis les sommets (une seule fraction  $\tau$ ), garder les **composantes** assez grandes : une seule sur FIND, toutes ailleurs
- ▶ **Arbre couvrant minimal** par composante : la réponse épaisse devient une structure d'axe unique [EUVIP 26]
- ▶ **Centralité pondérée sur l'arbre**, en  $\mathcal{O}(|V|)$  : masses des sous-arbres accumulées, réenracinement au maximum, élagage descendant ; seul l'axe principal reste
- ▶ **La suite, à l'ordre 2** : deux arêtes ne se recollent que par un **triangle** [ANS 26] [ISPRS 26+]

Sur FIND, **sans apprentissage** : 63 % de JACCARD en fusionnant les trois modalités (60 % à deux) ; CrackSegDiff, supervisé, atteint 87 % sur données propres, mais s'effondre sous le bruit


[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

[ISPRS 26+] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, article en préparation pour l'*ISPRS Journal of Photogrammetry and Remote Sensing*, 2026.




## VT-GraF : la connexité $K = 2$ sur le terrain



- ▶ Visible granulaire + thermique : la réponse de Frangi seule est noyée dans les cailloux
- ▶ Les composantes triangles-connexes éliminent les artefacts granulaires



## Sans entraînement... et robuste




Vaches Noires : vérité (vert), nous (rouge), U-Net + *transfer learning* (bleu)


- Compétitif avec un U-Net ayant coûté deux jours d'annotation experte
- CrackSegDiff : 87 % vs. 63 % de Jaccard sur données propres... mais s'effondre hors distribution



## Transferts sans réentraînement




Palais des Papes : la fracture principale



CrackForest : Jaccard 78 %, Wasserstein 5 px




## Sensibilité aux paramètres



Seuil relatif  $\tau$  : optimum net vers  $\tau \approx 0,2$  (graphe fragmenté vs. ponts parasites)



# SAM gelé, LoRA et la hiérarchie : le montage



- **SAM reconnaît** les fissures et le fond : ses poids restent **gelés** [SAM 2 24]
- **L'arbre rapproche** deux morceaux d'une même fissure reliés par une chaîne de raccords compatibles, même loin dans l'image : le bonus  $B_H$  est d'autant plus fort que leur **fusion** dans le graphe de FRANGI est **précoce** [EUVIP 26] [MALIS 09]
- **LoRA apprend** avec ce **guidage**, pondéré par un **seul** coefficient  $\beta$ , parti de zéro [LoRA 22]

Objectif : moins de **ruptures**, pas plus de **faux raccords** — témoin : la simple proximité spatiale. **Rien n'est encore mesuré**

[SAM 2 24] N. Ravi *et al.*, « SAM 2 : segment anything in images and videos », 2024.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.

[MALIS 09] S. C. Turaga, K. L. Briggman, M. Helmstaedter, W. Denk, H. S. Seung, « Maximin affinity learning of image segmentation », NIPS, 2009.

[LoRA 22] E. J. Hu *et al.*, « LoRA : low-rank adaptation of large language models », ICLR, 2022.