

Utilisation de graphes pour la classification et l'extraction de structures

Généralisation à des interactions d'ordre supérieur



Soutenance de thèse, mardi 8 septembre 2026

Learning Centre SophiaTech, Université Côte d'Azur

Louis HAUSEUX (Centre Inria d'Université Côte d'Azur ; bourse 3IA-DS4H)

Thèse dirigée par Konstantin AVRACHENKOV (NEO) et co-encadrée par Josiane ZERUBIA (AYANA)

Rapporteurs : Dieter MITSCHKE (PUC de Chile), Hocine CHERIFI (Univ. de Bourgogne)

Examineurs : Nicolas NISSE (Inria), Pierre CHARBONNIER (Cerema), Zoltan KATO (Univ. de Szeged)

01

Prologue : une ancienne énigme





Une ancienne énigme...

Un classificateur non-supervisé utilisant les
complexes simpliciaux
(avec une application à la *stylométrie*).

LOUIS HAUSEUX
Encadré par BARTŁOMIEJ BŁASZCZYSZYN

juillet 2017


Avant-propos

Stage à l'Inria Paris, équipe DYOGENE-MATHNET, encadré par Bartłomiej BŁASZCZYSZYN

[HAL 17]

[HAL 17] L. Hauseux (encadré par B. Błaszczyszyn), « Un classificateur non-supervisé utilisant les complexes simpliciaux », Inria Paris, 2017. HAL : hal-01597846.


Le sujet à la mode : l'homologie *persistante*



Faire croître un rayon r ; regarder les structures **naître, vivre, mourir** [Ghrist 08]



...avec une application à la *stylométrie*




- ▶ Une matrice de **Gram** : similarité 500×500 entre articles de presse
- ▶ **5 auteurs** anonymes, 100 articles chacun (statistiques de style : vocabulaire, catégories grammaticales, ponctuation, etc.)
- ▶ **But (non supervisé)** : rendre à chaque auteur ses 100 articles

Ici, les articles sont *triés* par auteur : les 5 blocs diagonaux sautent aux yeux... mais l'algorithme ne voit qu'une matrice mélangée



Une heuristique inspirée de la persistance



- Faire croître le seuil de similarité
- Observer les composantes « **triangles-connexes** »
(des k -simplexes recollés par facettes)
- Les voir **naître, grandir, fusionner**
- S'arrêter : une proportion P est couverte

Les « polyèdres » retournés ($k = 2$) [HAL 17]



Et... cela marche bien



- ▶ **2 auteurs** : 1 erreur, 1 non-classé (sur 100)
- ▶ Mieux que le K -Means...
- ▶ ... et que des mélanges gaussiens *semi-supervisés*
- ▶ Et sur **5 auteurs** : 4 clusters retrouvés

Pourquoi cela marche-t-il si bien ?



Plan

- I) Prologue : une ancienne énigme
- II) Du Single-Linkage à ses fondements
- III) Monter en ordre : la hiérarchie K -NN exacte
- IV) La percolation comme mesure de performance
- V) Applications : LiDAR 3D/4D, sans apprentissage
- VI) Vers des données davantage structurées
- VII) Conclusion & perspectives


02

Du Single-Linkage à ses fondements



Le clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^p$

Modèle de Hartigan [Hartigan 81] : les amas de forte densité




[Hartigan 81] J. A. Hartigan, « Consistency of Single Linkage for high-density clusters », JASA, 1981.


[Campello 13] R. Campello, D. Moulavi, J. Sander, « Density-based clustering based on hierarchical density estimates » (HDBSCAN), PAKDD, 2013.



Deux exemples issus de la thèse



Cosmologie 3D : filaments de galaxies [CN 23]



Huiles d'olive ($\mathbb{R}^8$) : hiérarchie obtenue [ANS 26]

[CN 23] L. Hauseux, K. Avrachenkov, J. Zerubia, « Graph based approach for galaxy filament extraction », *Complex Networks & Their Applications*, Menton, 2023.

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau $\{f \geq \lambda\}$

Arbre hiérarchique



C_1



Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau $\{f \geq \lambda\}$



Arbre hiérarchique



Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau $\{f \geq \lambda\}$



Arbre hiérarchique



Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau $\{f \geq \lambda\}$



Arbre hiérarchique





En pratique : estimer la densité

$$\hat{f} \leftarrow \hat{f}_{K\text{-NN}}$$

Estimateur des K plus proches voisins


$$\forall \mathbf{x} \in \mathbb{R}^p, \quad \hat{f}_{K\text{-NN}}(\mathbf{x}) = \frac{K}{n \omega_p r_K(\mathbf{x})^p}$$

- ▶ n : nombre de points de $\mathcal{X}$
- ▶ ω_p : volume de la boule unité de $\mathbb{R}^p$
- ▶ $r_K(\mathbf{x})$: distance de $\mathbf{x}$ à son K^{e} plus proche voisin

$$r_K(\mathbf{x}) = \min \{r \geq 0 \mid |B(\mathbf{x}, r) \cap \mathcal{X}| \geq K\}$$



Le cas $K = 1$: un « miracle » géométrique





Le cas $K = 1$: un « miracle » géométrique




$$\begin{aligned}\hat{\lambda}(x) &\geq \lambda_0 \\ \Leftrightarrow r_1(x) &\leq r_0\end{aligned}$$

Ensembles de niveau
= **modèle booléen**



Le cas $K = 1$: un « miracle » géométrique



$$\hat{\lambda}(x) \geq \lambda_0$$
$$\Leftrightarrow r_1(x) \leq r_0$$

Amas de forte densité
= **composantes connexes**
d'un **graphe géométrique** [Penrose 03]



Le cas $K = 1$: un « miracle » géométrique




$$r_1(x) \leq r_0$$

Amas de forte densité
= **composantes connexes**
d'un **graphe géométrique** [Penrose 03]



Le cas $K = 1$: un « miracle » géométrique




$$r_1(x) \leq r_0$$

Amas de forte densité
= **composantes connexes**
de l'**arbre minimum couvrant** élagué



L'arbre minimum couvrant et la triangulation de Delaunay

Cette hiérarchie a un nom :
le **Single-Linkage** [Florek 51]
[Gower-Ross 69]



L'arbre minimum couvrant euclidien
vit dans la triangulation de DELAUNAY
[Boissonnat 18] :

arbre minimum couvrant $\subseteq$ DELAUNAY


Dans le plan $\mathbb{R}^2$:

► Au plus $3n - 6$ arêtes

[Florek 51] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, S. Zubrzycki, « Sur la liaison et la division des points d'un ensemble fini », *Colloq. Math.*, 1951.
[Gower-Ross 69] J. C. Gower, G. J. S. Ross, « Minimum spanning trees and Single-Linkage cluster analysis », *JRSS C*, 1969.

[Boissonnat 18] J.-D. Boissonnat, F. Chazal, M. Yvinec, *Geometric and Topological Inference*, Cambridge University Press, 2018.

L'effet de chaînage et le Robust Single-Linkage



Effet de chaînage : une chaîne de points suffit à fusionner deux amas



Robust Single-Linkage [Chaudhuri-Dasgupta 10] :

- ▶ La *core distance* $r_K(x)$ estime la densité locale
- ▶ La distance devient la *mutual reachability*
- ▶ Les points isolés sont repoussés


Les descendants : DBSCAN, puis HDBSCAN

DBSCAN [Ester 96] : points *cœurs* ($r_K(x) \leq r$) vs. points *accessibles* : réintègre la frontière des amas

HDBSCAN [Campello 13] : fait varier le seuil r continûment et extrait les clusters par **excès de masse**



$$E(C) = \int_C (f(x) - \lambda) dx$$



Aire violette > aire verte + aire rouge
 $\Rightarrow$ Garder C_4

(plutôt que scinder en C_1 et C_2)

[Ester 96] M. Ester, H.-P. Kriegel, J. Sander, X. Xu, « A density-based algorithm for discovering clusters » (DBSCAN), KDD, 1996

03

Monter en ordre : la hiérarchie K -NN exacte



Que font Robust SL / (H)DBSCAN pour $K = 2$?

Nuage de points et boules de rayon r



Arbre hiérarchique obtenu



Un dendrogramme **plat** : toute l'information hiérarchique fine est perdue



La vraie hiérarchie 2-NN : échelle r

Les 2-intersections de boules au niveau r



Arbre hiérarchique



Étape 1 : les 7 segments fusionnent au seuil r



La vraie hiérarchie 2-NN : échelle r'

Triangles et 3-intersections à r'



Arbre hiérarchique




Étape 2 : fusion des triangles à r' via les 3-intersections. L'arête CD reste isolée



La vraie hiérarchie 2-NN : échelle r''

Connexité globale à r''



Arbre hiérarchique




Étape 3 : connexité globale à r'' par les points de tangence

Le diagnostic

Robust SL ($K = 2$)



Vraie hiérarchie 2-NN




Une asymétrie : condition d'ordre K sur les **points**, mais connexité d'ordre 1 par les **arêtes**



La réparation : le complexe de Čech et les K -polyèdres

- ▶ **Graphe géométrique** $\longrightarrow$ **complexe de Čech** :
un K -simplexe = $K + 1$ boules qui s'intersectent
- ▶ **Composantes connexes** $\longrightarrow$ **K -polyèdres** :
des $(K - 1)$ -simplexes recollés par des K -simplexes
- ▶ Pour $K \geq 2$, les clusters peuvent **se recouvrir**

Théorème [ANS 26] [EUSIPCO 24] : à tout niveau, les K -polyèdres identifient *exactement* les amas discrets de forte densité de l'estimateur $\hat{f}_{K\text{-NN}}$. Pour $K = 1$: le Single-Linkage




[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.


[EUSIPCO 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Benefits of hypergraphs for density-based clustering », *EUSIPCO*, Lyon, 2024.

Qui provoque les fusions ? La condition de Gabriel

- ▶ **Arête de l'arbre minimum couvrant** $\rightarrow$ **simplexe K -séparant** :
le simplexe qui provoque une **fusion**
- ▶ **Cas $K = 1$** : les 1-séparants sont exactement les arêtes de l'arbre minimum couvrant
- ▶ **Théorème [ANS 26]** : tout simplexe K -séparant est un simplexe de **Gabriel**
(sa boule minimale est vide d'intrus)



Triangle de Gabriel (boule vide)



Non-Gabriel (boule non vide)



K -arbre couvrant et mosaïque de Delaunay d'ordre K


- ▶ **Fusions critiques** : les simplexes K -séparants, tous K -GABRIEL (boule minimale vide)
- ▶ **Arbre couvrant** $\longrightarrow$ **K -arbre couvrant** : élagué à r , il redonne les K -polyèdres [ANS 26]
- ▶ **Delaunay** $\longrightarrow$ **mosaïque d'ordre K** : elle porte tous les simplexes K -GABRIEL [Edelsbrunner-Osang 23]
- ▶ Pour $K = 2$: tout se lit dans DELAUNAY, en $\mathcal{O}(n \log n)$ dans le plan

Analogie ordre 1 vs. ordre K


	$K = 1$	$K \geq 2$
Sommets	points	$(K - 1)$ -simplexes
Fusions	arêtes	K -simplexes
Condition	GABRIEL	GABRIEL
Domaine	DELAUNAY	DELAUNAY d'ordre K



En pratique ($K = 2$) : les huiles d'olive italiennes [Forina 83]



HDBSCAN : 3 macro-régions



2-polyèdres : 8 des 9 provinces retrouvées

572 points de $\mathbb{R}^8$: précision 96.1%, au-delà de l'état de l'art [Rolle-Scoccola 23] [ANS 26]
[Forina 83] M. Forina, C. Armanino, S. Lanteri, E. Tiscornia, « Classification of olive oils from their fatty acid composition », 1983 (jeu de données).


[Rolle-Scoccola 23] A. Rolle, L. Scoccola, « Stable and consistent density-based clustering » (Persistable), JMLR, 2024.

04

La percolation comme mesure de performance



Le phénomène au cœur de tout : la percolation continue



$$r < r_c$$


$$r = r_c$$

$$r > r_c$$

Au-delà d'un seuil critique, une **composante géante** (en rouge) émerge [Penrose 03]




Pourquoi le Single-Linkage échoue en dimension ≥ 2



Deux amas denses, A et B (les carrés), sur un fond de faible densité




Pourquoi le Single-Linkage échoue en dimension ≥ 2



Arbre couvrant élagué au rayon r_1 : la percolation a lieu dans chaque carré, pas sur le fond




Pourquoi le Single-Linkage échoue en dimension ≥ 2



Au rayon $r_2 > r_1$, le fond percole aussi : A et B fusionnent *avant* d'avoir été entièrement récupérés



La fraction récupérable




Probabilité de percolation des K -polyèdres

- $\Theta(\lambda)$: fraction des points dans la **composante géante**
- Sous le seuil critique λ_c : $\Theta = 0$
- La **fraction récupérable** d'un amas se lit sur la courbe



Quantifier : la *vitesse de percolation*



Probabilité de percolation des composantes du Robust Single-Linkage

$$v = \frac{\lambda_{\varepsilon}}{\lambda_{1-\varepsilon}}$$

- λ_{ε} : le fond **commence** à percoler ($\Theta = \varepsilon$)
- $\lambda_{1-\varepsilon}$: l'amas est presque **entier** ($\Theta = 1 - \varepsilon$)
- Plus v est **proche de 1**, meilleur est l'algorithme **[Sigm SRC] [CN 24]**

[Sigm SRC] L. Hauseux, « How can we theoretically measure the performance of density-based clustering algorithms ? », ACM SIGMETRICS SRC, Venice, 2024 (2^e prix).

[CN 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Hypergraphs, percolation and hierarchical clustering », *Complex Networks & Their Applications*, Istanbul, 2024.



Vitesses de percolation mesurées

K	$p = 2$			$p = 3$			$p = 4$		
	HGP	Robust SL	DBSCAN	HGP	Robust SL	DBSCAN	HGP	Robust SL	DBSCAN
1	0,735	0,735	0,735	0,563	0,563	0,563	0,362	0,362	0,362
2	0,779	0,689	0,735	0,646	0,462	0,563	0,451	0,271	0,362
3	0,800	0,632	0,753	0,690	0,412	0,582	0,497	0,247	0,378
4	0,817	0,598	0,767	0,714	0,400	0,605	0,500	0,246	0,409
5	0,826	0,584	0,779	0,732	0,399	0,625	0,534	0,236	0,415

- ▶ Les K -polyèdres (HGP) : la vitesse **croît** avec K , dans toutes les dimensions
- ▶ Robust SL : augmenter K **dégrade** les performances (jeter la frontière des amas est rédhibitoire)
- ▶ DBSCAN répare partiellement... mais sa connectivité reste celle des cœurs, qui percolent trop tôt


05

Applications : LiDAR 3D/4D, sans apprentissage



La hiérarchie devient un espace de résolution

- ▶ L'arbre hiérarchique n'est pas qu'une sortie :
on peut y **injecter des *a priori*** géométriques
- ▶ **Détection d'anomalies 3D** : comparaison au modèle théorique du navire (© NAVAL GROUP)
- ▶ Benchmark de 2×10^6 points : objets **parfaitement isolés**, sans aucun apprentissage



Modèle de référence en rouge, anomalies en couleurs

Panoptique 4D : des *a priori* plutôt que des annotations

- ▶ État de l'art : sémantique profonde + clustering spatial [Sautier 25] [Oh 25]
- ▶ Nos *a priori* faibles : volumes attendus des objets (véhicules, piétons) injectés dans la hiérarchie
- ▶ Association temporelle par **transport optimal** déséquilibré + filtre de KALMAN, *training-free*



A priori géométriques appliqués aux volumes des instances


[Sautier 25] C. Sautier & al., « Alpine : is clustering enough for LiDAR instance segmentation ? », 2025.

[Oh 25] M. Oh & al., « Geo-4D : training-free global geometric association for 4D LiDAR panoptic segmentation », 2025.




Résultats sur SemanticKITTI (200 trames)

Vérité terrain



Notre algorithme



Suivi des instances : aucun apprentissage, ni pour le clustering ni pour l'association

06

Vers des données davantage structurées







Quand la structure n'est plus (seulement) la géométrie

Deux terrains d'exploration, deux mêmes idées :

- 1) les interactions d'ordre supérieur apportent la robustesse ;
- 2) la percolation gouverne les performances




Graphes signés : les liens *créent* les communautés



Images : extraire des réseaux de fissures

Détection de communautés sur graphes signés



- Un **cadre bayésien** pour les graphes signés (attractions et répulsions) [Sankararaman-Baccelli 18]
- Des **dynamiques de clusters** d'ordre supérieur [Swendsen-Wang 87]
- La **percolation** des amas gelés conditionne le recouvrement :
des bornes plus fines [Asilomar 25] [I&I 26+]


[Sankararaman-Baccelli 18] A. Sankararaman, F. Baccelli, « Community detection on Euclidean random graphs », *ACM-SIAM SODA*, 2018.

[Swendsen-Wang 87] R. H. Swendsen, J.-S. Wang, « Nonuniversal critical dynamics in Monte Carlo simulations », *Physical Review Letters*, 1987.

[Asilomar 25] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs », *Asilomar*, 2025.

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article de journal en cours de rédaction, 2026.

Au-delà de Swendsen–Wang : triangles et hiérarchie



- ▶ Face à la frustration, le gel **corrélé par triangles** gèle moins... et percole plus tard
- ▶ Une **hiérarchie d'horloges** : chaque arête satisfaite reçoit $\xi_e \sim \text{Exp}(|W_e|)$;
couper le dendrogramme à l'instant β donne une dynamique invariante
- ▶ Les **racines** ($\beta = 1$) redonnent Swendsen–Wang ; les **feuilles** ($\beta = 0$), Glauber [I&I 26+]




Le recouvrement reformulé en percolation

$$\text{ov} \leq \frac{1}{K} + \frac{K-1}{K} \theta^{\max}$$


$\theta^{\max}$: masse des composantes **géantes** de l'objet gelé

- ▶ Pour **toute** dynamique de clusters invariante : **sans percolation, pas de recouvrement**
- ▶ Un pas de SW standard $\Rightarrow$ percolation $f_{\text{in}} - f_{\text{out}}$: le théorème de [Sankararaman-Baccelli 18], **exactement**
- ▶ La dynamique triangulaire percole plus tard : borne **strictement meilleure** (sur la grille triangulaire : p_c passe de 0,674 à 0,719) [Asilomar 25] [I&I 26+]


Extraction de réseaux de fissures sur images




intensité



profondeur



similarité du graphe



squelette extrait

- Du **pixel** (filtre de FRANGI [Frangi 98]) à la **paire de pixels** (graphe de Frangi [GRETSI 25])
- **Multimodal**, sans apprentissage ; la connexité $K = 2$ bloque la percolation du bruit [EUVIP 26]
- Robuste hors distribution ; la sortie est un **graphe éditable** [ISPRS 26+]

[Frangi 98] A. F. Frangi, W. J. Niessen, K. L. Vincken, M. A. Viergever, « Multiscale vessel enhancement filtering », MICCAI, 1998.


[GRETSI 25] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Généralisation du filtre de Frangi pour l'extraction des réseaux de fissures », GRETSI, 2025.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.

[ISPRS 26+] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, article en préparation pour ISPRS Journal of Photogrammetry and Remote Sensing, 2026.



Et ensuite ? Guider un modèle de fondation



Un réseau entièrement manqué par la baseline, retrouvé (IoU
 $0 \rightarrow 0,22$)

- ▶ SAM 2 + LoRA + **11 canaux d'évidence géométrique**, injectés à initialisation nulle
- ▶ Acquis : la **perte tolérante** (3 px), issue de l'incertitude d'annotation, bat la baseline
- ▶ Contrôle causal (évidence permutée) : en monomodal, la géométrie n'ajoute rien...
- ▶ ... la perspective : le **multimodal**, où SAM n'a pas accès à cette information **[ISPRS 26+]**

07

Conclusion & perspectives





Deux piliers, quatre contributions

1) Quand les relations binaires sont insuffisantes ou instables, les **interactions d'ordre supérieur** apportent une cohérence robuste.

2) La **percolation** est la clef de voûte théorique pour quantifier les performances de ces algorithmes

- ▶ Une **vue unifiée** du Single-Linkage : heuristique (arbre couvrant), géométrique (percolation), statistique (HARTIGAN), avec applications LiDAR 3D/4D sans apprentissage [ANS 26]
- ▶ **HGP-Clusterer** : la hiérarchie K -NN exacte, *via* Čech, GABRIEL et la mosaïque de DELAUNAY d'ordre K [EUSIPCO 24] [CN 24]
- ▶ La **vitesse de percolation** : une mesure quantitative qui explique l'échec de Robust SL / (H)DBSCAN et la supériorité des K -polyèdres [Sigm SRC]
- ▶ L'**export du paradigme** : graphes signés (dynamiques d'ordre supérieur, bornes plus fines) [Asilomar 25] et imagerie (graphe de Frangi multimodal) [GRETSI 25] [EUVIP 26]

- ▶ **Réduction de dimension d'ordre supérieur** : la mosaïque de DELAUNAY d'ordre K est bien plus riche que les graphes de voisinage (UMAP) : la piste privilégiée
- ▶ **Question ouverte assumée** : HGP-Clusterer n'est que *fractionnellement* consistant ; un algorithme consistant en dimension $p \geq 2$ reste à inventer
- ▶ **Graphes signés** : couplage à deux répliques pour des seuils exacts de recouvrement ; vers un algorithme pratique de détection de communautés
- ▶ **Fissures** : un logiciel d'aide à l'annotation experte fondé sur les graphes ; réconcilier modèles géométriques et apprentissage profond

Publications

Journal

- ▶ **[ANS 26]** *Generalization of Single-Linkage with higher-order interactions*, Applied Network Science, 2026

Conférences internationales et nationales

- ▶ **[CN 23]** Filaments de galaxies, Complex Networks, Menton, 2023
- ▶ **[EUSIPCO 24]** Hypergraphes pour le clustering par densité, EUSIPCO, Lyon, 2024
- ▶ **[CN 24]** Hypergraphes, percolation et clustering hiérarchique, Complex Networks, Istanbul, 2024
- ▶ **[Sigm SRC]** Mesure théorique de performance, ACM SIGMETRICS SRC, Venise, 2024 (**2^e prix**)
- ▶ **[Asilomar 25]** Dynamiques de clusters d'ordre supérieur, Asilomar, 2025
- ▶ **[GRETSI 25]** Généralisation du filtre de Frangi, GRETSI, Strasbourg, 2025
- ▶ **[EUVIP 26]** Extraction multimodale de fissures sans apprentissage, EUVIP, Luxembourg, 2026

En cours

- ▶ **[I&I 26+]** Cadre bayésien pour la détection de communautés sur graphes signés (journal)
- ▶ **[ISPRS 26+]** Graphe de Frangi généralisé, multimodal et sans apprentissage (journal ISPRS)

Logiciel : dépôts GitHub Ayana-Inria/HypergraphPercol_K2 et Ayana-Inria/Frangi-EUVIP

Merci.





Bibliographie

- ▶ [Florek 51] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, S. Zubrzycki, « Sur la liaison et la division des points d'un ensemble fini », Colloq. Math., 1951.
- ▶ [Gower-Ross 69] J. C. Gower, G. J. S. Ross, « Minimum spanning trees and Single-Linkage cluster analysis », JRSS C, 1969.
- ▶ [Hartigan 81] J. A. Hartigan, « Consistency of Single Linkage for high-density clusters », JASA, 1981.
- ▶ [Forina 83] M. Forina, C. Armanino, S. Lanteri, E. Tiscornia, « Classification of olive oils from their fatty acid composition », 1983 (jeu de données).
- ▶ [Swendsen-Wang 87] R. H. Swendsen, J.-S. Wang, « Nonuniversal critical dynamics in Monte Carlo simulations », *Physical Review Letters*, 1987.
- ▶ [Ester 96] M. Ester, H.-P. Kriegel, J. Sander, X. Xu, « A density-based algorithm for discovering clusters » (DBSCAN), KDD, 1996.
- ▶ [Frangi 98] A. F. Frangi, W. J. Niessen, K. L. Vincken, M. A. Viergever, « Multiscale vessel enhancement filtering », MICCAI, 1998.
- ▶ [Penrose 03] M. Penrose, *Random Geometric Graphs*, Oxford University Press, 2003.
- ▶ [Ghrist 08] R. Ghrist, « Barcodes : the persistent topology of data », Bulletin of the AMS, 2008.
- ▶ [Chaudhuri-Dasgupta 10] K. Chaudhuri, S. Dasgupta, « Rates of convergence for the cluster tree », *NeurIPS*, 2010.
- ▶ [Campello 13] R. Campello, D. Moulavi, J. Sander, « Density-based clustering based on hierarchical density estimates » (HDBSCAN), PAKDD, 2013.
- ▶ [Boissonnat 18] J.-D. Boissonnat, F. Chazal, M. Yvinec, *Geometric and Topological Inference*, Cambridge University Press, 2018.
- ▶ [Sankararaman-Baccelli 18] A. Sankararaman, F. Baccelli, « Community detection on Euclidean random graphs », *ACM-SIAM SODA*, 2018.
- ▶ [Edelsbrunner-Osang 23] H. Edelsbrunner, G. Osang, « A simple algorithm for higher-order Delaunay mosaics and alpha shapes », *Algorithmica*, 2023.
- ▶ [Rolle-Scoccola 23] A. Rolle, L. Scoccola, « Stable and consistent density-based clustering » (Persistable), JMLR, 2024.
- ▶ [Sautier 25] C. Sautier & al., « Alpine : is clustering enough for LiDAR instance segmentation ? », 2025.
- ▶ [Oh 25] M. Oh & al., « Geo-4D : training-free global geometric association for 4D LiDAR panoptic segmentation », 2025.



Bibliographie : travaux de l'auteur


- ▶ **[HAL 17]** L. Hauseux (encadré par B. Błaszczyszyn), « Un classificateur non-supervisé utilisant les complexes simpliciaux », Inria Paris, 2017. HAL : hal-01597846.
- ▶ **[CN 23]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Graph based approach for galaxy filament extraction », *Complex Networks & Their Applications*, Menton, 2023.
- ▶ **[EUSIPCO 24]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Benefits of hypergraphs for density-based clustering », *EUSIPCO*, Lyon, 2024.
- ▶ **[CN 24]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Hypergraphs, percolation and hierarchical clustering », *Complex Networks & Their Applications*, Istanbul, 2024.
- ▶ **[Sigm SRC]** L. Hauseux, « How can we theoretically measure the performance of density-based clustering algorithms? », ACM SIGMETRICS SRC, Venise, 2024 (2^e prix).
- ▶ **[ANS 26]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.
- ▶ **[GRETSI 25]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Généralisation du filtre de Frangi pour l'extraction des réseaux de fissures », GRETSI, 2025.
- ▶ **[Asilomar 25]** L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs », Asilomar, 2025.
- ▶ **[EUVIP 26]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.
- ▶ **[I&I 26+]** L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article de journal en cours de rédaction, 2026.
- ▶ **[ISPRS 26+]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, article en préparation pour ISPRS Journal of Photogrammetry and Remote Sensing, 2026.

Slides de secours






Stylométrie 2017 : le cas à 5 auteurs



- ▶ 5 auteurs $\times$ 40 textes ($P = 70\%$, $k = 5$)
- ▶ 4 classes correctement identifiées...
- ▶ ... mais la 4^e (textes 120–159) est manquée
- ▶ Ronds noirs : non classés ; étoiles : multi-classes

Benchmark SIPU : toutes choses égales par ailleurs



Même $\text{min_cluster_size} = \sqrt{n}$, même excès de masse :
la seule différence est la **connexité triangulaire**

Jeu	HDBSCAN	2-polyèdres
a2	0,762	0,834
a3	0,696	0,831
d31	0,660	0,835
s2	0,780	0,842
s3	0,251	0,418
birch2	0,996	0,998

ARI ; grille : vérité, HDBSCAN, notre algorithme



Huiles d'olive : la matrice de confusion

Pers./Ours	1	2	3	4	5	6	7	8	9	Miss.
N. Apulia	12/24	0/0	0/0	-	0/0	0/0	0/0	0/0	0/0	13/1
Calabria	0/0	7/25	1/2	-	0/0	0/0	0/0	0/0	0/0	48/29
S. Apulia	0/0	0/0	100/145	-	0/0	0/0	0/0	0/0	0/0	106/61
Sicilia	3/6	0/1	0/2	-	0/0	0/0	0/0	0/0	0/0	33/27
Inl. Sard.	0/0	0/0	0/0	-	51/62	0/0	0/0	0/0	0/0	14/3
Coast S.	0/0	0/0	0/0	-	0/2	19/29	0/0	0/0	0/0	14/2
E. Ligur.	0/0	0/0	0/0	-	0/0	0/0	14/32	1/2	0/1	35/15
W. Ligur.	0/0	0/0	0/0	-	0/0	0/0	0/0	29/33	0/0	21/17
Umbria	0/0	0/0	0/0	-	0/0	0/0	0/0	0/0	42/46	9/5

- ▶ 412/572 points classés (72 %), dont 96,1 % correctement
- ▶ Persistable [Rolle-Scoccola 23] : 49 % classés seulement
- ▶ En partition exhaustive : ARI 0,890 contre 0,848



Vitesses de percolation : le protocole

- ▶ $\mathcal{X}$: $n = 100\,000$ points uniformes dans $\left[0, n^{1/p}\right]^p$ ($n = 10\,000$ en dimension 4)
- ▶ $T = 100$ tirages indépendants ; rappel $\varepsilon = 3\%$
- ▶ Pour chaque algorithme (HGP, Robust SL, DBSCAN) : rayons de fusion et taille de la plus grande composante
- ▶ Estimateur $\hat{v} = \hat{\lambda}_\varepsilon / \hat{\lambda}_{1-\varepsilon}$
- ▶ Repère : seuil critique du modèle booléen ($K = 1$, 2D) : $\lambda_c \approx 1,44$




Quand $K \rightarrow +\infty$: la fenêtre gaussienne


- ▶ Dans la fenêtre $\mu = K + a\sqrt{K}$, les niveaux K -NN convergent vers les **excursions** $E_a = \{G_p \geq -a\}$ d'un champ gaussien
- ▶ Covariance du champ : le volume d'intersection de deux boules
- ▶ Les trois algorithmes ne diffèrent que par l'**ordre des opérations** : dilater puis connecter (cœurs, DBSCAN) vs. connecter puis dilater (polyèdres)
- ▶ Seuils de bruit : $a_c^{\text{poly}} \geq a_c^{\text{core}}$, vitesse asymptotiquement meilleure pour les K -polyèdres



L'état de l'art LiDAR



Alpine [Sautier 25] : « is clustering enough ? »



Geo-4D [Oh 25] : association géométrique 4D




L'assemblage d'haplotypes

Un graphe signé bruité


Nœuds = lectures ADN ; arêtes = chevauchements (attractions / répulsions)

But : retrouver l'affectation cachée Σ





Le cadre bayésien et l'hypothèse de Gibbs



$$U(\sigma) = \sum_{e \in F} W_e \mathbb{I}_{\{\sigma_i \neq \sigma_j\}} + \sum_{e \in \tilde{F}} |W_e| \mathbb{I}_{\{\sigma_i = \sigma_j\}} \quad \mu_{X,W}(\sigma) = \frac{e^{-U(\sigma)}}{Z}$$

- ▶ F : arêtes attractives ($W_e > 0$); $\tilde{F}$: répulsives ($W_e < 0$); U pénalise les arêtes insatisfaites
- ▶ **Hypothèse de Gibbs** : la loi *a posteriori* est la mesure de Gibbs signée



Un pas de Swendsen–Wang signé, en détail

- ▶ **Gel** : chaque arête *satisfaite* est gelée avec probabilité $1 - e^{-|W_e|}$; les insatisfaites jamais
- ▶ **Recoloriage** : chaque amas gelé est recolorié uniformément au hasard
- ▶ La dynamique laisse la loi *a posteriori* invariante
- ▶ Un pas depuis la vérité Σ produit une **réplique** $\Sigma^{(1)} \sim \mu_{X,W}$ (identité de Nishimori) : un couplage entre vérité et observation
- ▶ Les petits amas sont recoloriés aveuglément : l'information globale ne survit que dans les **composantes géantes**



Le modèle de Sankararaman–Bacelli, en détail

- ▶ Nœuds : processus de Poisson dans $\mathbb{R}^p$; communautés $\Sigma_i \in \{\pm 1\}$ uniformes
- ▶ Arête $e = \{i, j\}$ présente avec probabilité $f_{\text{in}}(r_e)$ (même communauté) ou $f_{\text{out}}(r_e)$ (communautés différentes), $r_e = \|X_i - X_j\|$
- ▶ Poids signés reconstruits : $W_e = \log \frac{f_{\text{in}}(r_e)}{f_{\text{out}}(r_e)} \geq 0$ si e observée, $W_e = -\log \frac{1-f_{\text{out}}(r_e)}{1-f_{\text{in}}(r_e)} \leq 0$ sinon

$$\mathbb{P}(\text{arête gelée}) = f_{\text{in}}(r_e) \left(1 - e^{-|W_e|}\right) = f_{\text{in}}(r_e) - f_{\text{out}}(r_e)$$

- ▶ Le graphe gelé d'un pas de SW-arêtes est **exactement** la percolation indépendante de [Sankararaman-Bacelli 18]




La hiérarchie d'horloges, en détail

- ▶ Conditionnellement à $\sigma : \xi_e \sim \text{Exp}(|W_e|)$ sur les arêtes satisfaites, $\xi_e = +\infty$ sinon ; $\Pi_\beta =$ composantes de $\{\xi_e \leq \beta\}$; le dendrogramme s'obtient par KRUSKAL
- ▶ $\mathbb{P}(\xi_e \leq 1) = 1 - e^{-|W_e|}$: Π_1 est **exactement** la partition gelée de Swendsen–Wang
- ▶ Mesure jointe de type EDWARDS–SOKAL $\nu(\sigma, D)$; à chaque nœud, un **heat bath exact** sur les quatre orientations relatives des deux fils (balance détaillée, invariance)
- ▶ Le dendrogramme est **non marqué** : l'identité de l'arête gagnante est marginalisée — une fusion dépend de toute la coupe $\Lambda_u(\sigma) = \sum_{e \in E_u} |W_e| \mathbb{I}_{\{e \text{ satisfaite}\}}$
- ▶ Sur le tore triangulaire : Π_t suit une percolation indépendante $q_p(t) = p(1 - e^{-u_p t})$,
 $u_p = \log \frac{p}{1-p}$




L'échelle des seuils du GSBM triangulaire



- Gel SW $0,6736 < \text{triangles } 0,7192 < \text{info-percolation } 0,7947 < \text{record rigoureux } 0,8094$
- Point multicritique de Nishimori $0,8358$: conjecture




Calibration exacte sur le SBM



- ▶ Deux répliques, deux dendrogrammes **indépendants**, coupés au même β_c
- ▶ Chaque arête transmet exactement θ^2 : calibration $\beta_X = \beta_c \Leftrightarrow d\theta^2 = 1$ (le seuil de KESTEN-STIGUM)
- ▶ Quand le signal diverge, $\beta_{c,n} \rightarrow 0$: la coupe s'écrase d'elle-même sur Glauber




Validation à 10^6 nœuds : les trois régimes



$p = 0,70$: seules les arêtes standard percolent ; l'*overlap* reste au bruit




Validation à 10^6 nœuds : les trois régimes



$p = 0,72$: toutes les dynamiques percolent... mais l'*overlap* reste au bruit (nécessaire $\neq$ suffisant)




Validation à 10^6 nœuds : les trois régimes



$p = 0,80$: composantes géantes stables et **recouvrement effectif**





VT-GraF : la connexité $K = 2$ sur le terrain



- ▶ Visible granulaire + thermique : la réponse de Frangi seule est noyée dans les cailloux
- ▶ Les composantes triangles-connexes éliminent les artefacts granulaires



Sans entraînement... et robuste




Sous bruit croissant, notre méthode (rouge) reste stable

Vaches Noires : vérité (vert), nous (rouge), U-Net (bleu)


- ▶ Compétitif avec un U-Net ayant coûté deux jours d'annotation experte
- ▶ CrackSegDiff : 87 % vs. 63 % de Jaccard sur données propres... mais s'effondre hors distribution



Transferts sans réentraînement




Palais des Papes : la fracture principale



CrackForest : Jaccard 78 %, Wasserstein 5 px




Sensibilité aux paramètres




Seuil relatif τ : optimum net vers $\tau \approx 0,2$ (graphe fragmenté vs. ponts parasites)



CrackSAM-GeoLoRA : le protocole causal



Six variantes, IoU stricte sur 1 695 images de test (corpus Khánh Hà)



Évidence alignée vs. permutée : sur la diagonale

- Baseline 0,6241 ; perte tolérante 0,6276 ; géométrie + tolérance 0,6270 $\approx$ évidence permutée 0,6265
- $|\Delta| < 0,001$ à toutes les tolérances : en monomodal, la géométrie n'apporte pas d'information nouvelle