

Utilisation de graphes pour la classification et l'extraction de structures

Généralisation à des interactions d'ordre supérieur

Soutenance de thèse, mardi 8 septembre 2026

Learning Centre SophiaTech, Université Côte d'Azur

Louis HAUSEUX (Centre Inria d'Université Côte d'Azur ; bourse 3IA-DS4H)

Thèse dirigée par Konstantin AVRACHENKOV (Inria, éq. NEO)

et co-encadrée par Josiane ZERUBIA (Inria, éq. AYANA)

Rapporteurs : Dieter MITSCHÉ (PUC de Chile), Hocine CHERIFI (Univ. de Bourgogne)

Examineurs : Nicolas NISSE (Inria, éq. COATI),

Pierre CHARBONNIER (Cerema), Zoltán KATÓ (Univ. de Szeged)

01

Prologue : une ancienne énigme





Une ancienne énigme...

Un classificateur non-supervisé utilisant les
complexes simpliciaux
(avec une application à la *stylométrie*).

LOUIS HAUSEUX
Encadré par BARTŁOMIEJ BŁASZCZYSZYN


juillet 2017

Avant-propos

Stage à l'Inria Paris, équipe DYOGENE-MATHNET [HAL 17]

[HAL 17] L. Hauseux (encadré par B. Błaszczyszyn), « Un classificateur non supervisé utilisant les complexes simpliciaux », Inria Paris, 2017. HAL : hal-01597846.


Le sujet à la mode : l'homologie *persistante*



Faire croître un rayon r ; regarder les structures **naître, vivre, mourir** [Ghrist 08]



...avec une application à la *stylométrie*




- ▶ Une matrice de **Gram** : similarité 500×500 entre articles de presse [HAL 17]
- ▶ **5 auteurs** anonymes, 100 articles chacun (statistiques de style : vocabulaire, catégories grammaticales, ponctuation, etc.)
- ▶ **But (non supervisé)** : rendre à chaque auteur ses 100 articles

Ici, les articles sont *triés* par auteur : les 5 blocs diagonaux sautent aux yeux... mais l'algorithme ne voit qu'une matrice mélangée



Une heuristique inspirée de la persistance




- Faire croître le seuil de similarité
- Observer les composantes « **triangles-connexes** »
(des k -simplexes recollés par facettes)
- Les voir **naître, grandir, fusionner**
- S'arrêter : une proportion P est couverte

Les « polyèdres » retournés ($k = 2$) [HAL 17]



Et... cela marche bien



- ▶ **2 auteurs** : 1 erreur, 1 article non classé (sur 100)
- ▶ Mieux que l'algorithme des k -moyennes...
- ▶ ... et que des mélanges gaussiens *semi-supervisés*
- ▶ Et sur **5 auteurs** : 4 amas retrouvés

Pourquoi cela marche-t-il si bien ?

Plan

- I) Prologue : une ancienne énigme
- II) Du *Single-Linkage* à ses fondements
- III) Monter à l'**ordre supérieur** : la hiérarchie K -NN exacte
- IV) La **percolation** comme mesure de performance
- V) Applications : LiDAR 3D et 4D, sans apprentissage
- VI) Vers des données davantage structurées
- VII) Perspectives : la voie **hiérarchique**
- VIII) Conclusion


02

Du *Single-Linkage* à ses fondements



Le *clustering* sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^p$

Modèle de Hartigan [Hartigan 81] : les amas de forte densité




[Hartigan 81] J. A. Hartigan, « Consistency of Single Linkage for high-density clusters », JASA, 1981.


[Campello 13] R. Campello, D. Moulavi, J. Sander, « Density-based clustering based on hierarchical density estimates » (HDBSCAN), PAKDD, 2013.



Deux exemples issus de la thèse



Cosmologie 3D : filaments de galaxies [CN 23]



Huiles d'olive ($\mathbb{R}^8$) : hiérarchie obtenue [ANS 26]

[CN 23] L. Hauseux, K. Avrachenkov, J. Zerubia, « Graph based approach for galaxy filament extraction », *Complex Networks & Their Applications*, Menton, 2023.

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau $\{f \geq \lambda\}$

Arbre hiérarchique



C_1



Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau $\{f \geq \lambda\}$



Arbre hiérarchique



Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau $\{f \geq \lambda\}$



Arbre hiérarchique



Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau $\{f \geq \lambda\}$



Arbre hiérarchique





En pratique : estimer la densité

$$\hat{f} \leftarrow \hat{f}_{K\text{-NN}}$$

Estimateur des K plus proches voisins [Biau–Devroye 15]


$$\forall x \in \mathbb{R}^p, \quad \hat{f}_{K\text{-NN}}(x) = \frac{K}{n \omega_p r_K(x)^p}$$

- ▶ n : nombre de points de $\mathcal{X}$
- ▶ ω_p : volume de la boule unité de $\mathbb{R}^p$
- ▶ $r_K(x)$: distance de x à son K^{e} plus proche voisin ; si $x \in \mathcal{X}$, on exclut x lui-même

$$r_K(x) = \min \{r \geq 0 \mid |B(x, r) \cap (\mathcal{X} \setminus \{x\})| \geq K\}$$



Le cas $K = 1$: un « miracle » géométrique





Le cas $K = 1$: un « miracle » géométrique




$$\hat{\lambda}(x) \geq \lambda_0$$
$$\Leftrightarrow r_1(x) \leq r_0$$

Ensembles de niveau
= **modèle booléen**



Le cas $K = 1$: un « miracle » géométrique



$$\hat{\lambda}(x) \geq \lambda_0$$
$$\Leftrightarrow r_1(x) \leq r_0$$

Amas de forte densité
= **composantes connexes**
d'un **graphe géométrique** [Penrose 03]



Le cas $K = 1$: un « miracle » géométrique



$$r_1(x) \leq r_0$$

Amas de forte densité
= **composantes connexes**
d'un **graphe géométrique** [Penrose 03]



Le cas $K = 1$: un « miracle » géométrique




$$r_1(x) \leq r_0$$

Amas de forte densité
= **composantes connexes**
de l'**arbre minimum couvrant** élagué



L'arbre minimum couvrant et la triangulation de Delaunay



Cette hiérarchie a un nom :
le **Single-Linkage** [Florek 51]
[Gower–Ross 69]

L'arbre minimum couvrant euclidien
vit dans la triangulation de DELAUNAY
[Boissonnat 18] :

arbre minimum couvrant $\subseteq$ DELAUNAY


Dans le plan $\mathbb{R}^2$: $\mathcal{O}(n \log n)$

[Florek 51] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, S. Zubrzycki, « Sur la liaison et la division des points d'un ensemble fini », Colloq. Math., 1951.

[Gower–Ross 69] J. C. Gower, G. J. S. Ross, « Minimum spanning trees and Single-Linkage cluster analysis », JRSS C, 1969.

[Boissonnat 18] J.-D. Boissonnat, F. Chazal, M. Yvinec, *Geometric and Topological Inference*, Cambridge University Press, 2018.

L'effet de chaînage et le *Robust Single-Linkage*



Effet de chaînage : une chaîne de points suffit à fusionner deux amas

Robust Single-Linkage

[Chaudhuri–Dasgupta 10] :

- ▶ La *core distance* $r_K(x)$ estime la densité locale
- ▶ La distance devient la *mutual reachability*
- ▶ Les points isolés sont repoussés

Les descendants : DBSCAN, puis HDBSCAN



DBSCAN [Ester 96] : points *cœurs* ($r_K(x) \leq r$) vs. points *accessibles* : réintègre la frontière des amas

HDBSCAN [Campello 13] : fait varier le seuil r continûment et extrait les amas par excès de masse

$$E(C) = \int_C (f(x) - \lambda) dx$$

03

Monter à l'ordre supérieur : la hiérarchie K -NN exacte



Que font Robust SL et (H)DBSCAN pour $K = 2$?

Nuage de points et boules de rayon r



Arbre hiérarchique obtenu



Un dendrogramme **plat** : toute l'information hiérarchique fine est perdue



La vraie hiérarchie 2-NN : échelle r

Les 2-intersections de boules au niveau r



Arbre hiérarchique



Étape 1 : les 7 segments fusionnent au seuil r



La vraie hiérarchie 2-NN : échelle r'

Triangles et 3-intersections à r'



Arbre hiérarchique




Étape 2 : fusion des triangles à r' via les 3-intersections. L'arête CD reste isolée



La vraie hiérarchie 2-NN : échelle r''

Connexité globale à r''




Arbre hiérarchique




Étape 3 : connexité globale à r'' par les points de tangence

Le diagnostic

Robust SL ($K = 2$)



Vraie hiérarchie 2-NN



Une asymétrie : condition d'ordre K sur les **points**, mais connexité d'ordre 1 par les **arêtes**



La réparation : le complexe de Čech et les K -polyèdres


- ▶ **Graphe géométrique** [Penrose 03] $\longrightarrow$ **complexe de Čech** :

un K -simplexe = $K + 1$ boules qui s'intersectent

- ▶ **Composantes connexes** $\longrightarrow$ **K -polyèdres** :
des $(K - 1)$ -simplexes recollés par des K -simplexes

- ▶ Pour $K \geq 2$, les amas peuvent **se recouvrir**

Théorème [ANS 26] [EUSIPCO 24] : à tout niveau, les K -polyèdres identifient *exactement* les amas discrets de forte densité de l'estimateur $\hat{f}_{K\text{-NN}}$. Pour $K = 1$: le *Single-Linkage*



[Penrose 03] M. Penrose, *Random Geometric Graphs*, Oxford University Press, 2003.


[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

[EUSIPCO 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Benefits of hypergraphs for density-based clustering », *EUSIPCO*, Lyon, 2024.


Qui provoque les fusions ? La condition de Gabriel

Arête de l'arbre minimum couvrant $\longrightarrow$ simplexe K -séparant

- ▶ Le simplexe K -séparant : celui qui provoque une fusion
- ▶ Cas $K = 1$: les 1-séparants sont exactement les arêtes de l'arbre minimum couvrant
- ▶ **Théorème [ANS 26]** : tout simplexe K -séparant est un simplexe de **Gabriel** (sa boule minimale est vide d'intrus)



Triangle de Gabriel (boule vide)



Non-Gabriel (boule non vide)



K -arbre couvrant et mosaïque de Delaunay d'ordre K


- ▶ **Fusions critiques** : les simplexes K -séparants, tous K -GABRIEL (boule minimale vide)
- ▶ **Arbre couvrant** $\longrightarrow$ **K -arbre couvrant** : élagué à r , il redonne les K -polyèdres [ANS 26]
- ▶ **Delaunay** $\longrightarrow$ **mosaïque d'ordre K** : elle porte tous les simplexes K -GABRIEL [Edelsbrunner–Osang 23]
- ▶ Pour $K = 2$: tout se lit dans DELAUNAY, en $\mathcal{O}(n \log n)$ dans le plan

Analogie ordre 1 vs. ordre K


	$K = 1$	$K \geq 2$
Sommets	points	$(K - 1)$ -simplexes
Fusions	arêtes	K -simplexes
Condition	arête GABRIEL	K -GABRIEL
Domaine	DELAUNAY	DELAUNAY d'ordre K



En pratique ($K = 2$) : les huiles d'olive italiennes [Forina 83]



HDBSCAN : 3 macrorégions



2-polyèdres : **8 provinces identifiées**
parmi les 72 % de points classés

Au-delà de l'état de l'art [Rolle–Scoccola 23] [ANS 26]

[Forina 83] M. Forina, C. Armanino, S. Lanteri, E. Tiscornia, « Classification of olive oils from their fatty acid composition », 1983 (jeu de données).


[Rolle–Scoccola 23] A. Rolle, L. Scoccola, « Stable and consistent density-based clustering » (Persistable), JMLR, 2024.

04

La **percolation** comme mesure de performance



Le phénomène au cœur de tout : la percolation continue



$$r < r_c$$


$$r = r_c$$

$$r > r_c$$

Au-delà d'un seuil critique, une **composante géante** (en rouge) émerge [Penrose 03]




Pourquoi le *Single-Linkage* échoue en dimension ≥ 2



Deux amas denses, A et B (les carrés), sur un fond de faible densité




Pourquoi le *Single-Linkage* échoue en dimension ≥ 2



Arbre couvrant élagué au rayon r_1 : la percolation a lieu dans chaque carré, pas sur le fond




Pourquoi le *Single-Linkage* échoue en dimension ≥ 2



Au rayon $r_2 > r_1$, le fond percole aussi : A et B fusionnent *avant* d'avoir été entièrement récupérés
[Penrose 03]



La fraction récupérable




Fraction de points dans la composante géante

- En abscisse : l'intensité λ ; en ordonnée : la fraction des points dans la **composante géante**
- Sous le seuil critique λ_c : rien
- La **fraction récupérable** d'un amas se lit sur la courbe



Quantifier : la *vitesse de percolation*



Probabilité de percolation des K -polyèdres

$$v = \frac{\lambda_c}{\lambda_{1-\varepsilon}}$$

- λ_c : le fond **commence** à percoler
- $\lambda_{1-\varepsilon}$: l'amas est presque **entier**
- Plus v est **proche de 1**, meilleur est l'algorithme
[SIGMETRICS SRC 24] [CN 24]

[SIGMETRICS SRC 24] L. Hauseux, « How can we theoretically measure the performance of density-based clustering algorithms ? », ACM SIGMETRICS SRC, Venice, 2024 (2^e prix).

[CN 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Hypergraphs, percolation and hierarchical clustering », *Complex Networks & Their Applications*, Istanbul, 2024.



Vitesses de percolation mesurées

K	$p = 2$			$p = 3$			$p = 4$		
	HGP	Robust SL	DBSCAN	HGP	Robust SL	DBSCAN	HGP	Robust SL	DBSCAN
1	0,735	0,735	0,735	0,563	0,563	0,563	0,362	0,362	0,362
2	0,779	0,689	0,735	0,646	0,462	0,563	0,451	0,271	0,362
3	0,800	0,632	0,753	0,690	0,412	0,582	0,497	0,247	0,378
4	0,817	0,598	0,767	0,714	0,400	0,605	0,500	0,246	0,409
5	0,826	0,584	0,779	0,732	0,399	0,625	0,534	0,236	0,415

- ▶ Les K -polyèdres : la vitesse **croît** avec K , dans toutes les dimensions
- ▶ Robust SL : augmenter K **dégrade** (jeter la frontière est rédhibitoire)
- ▶ DBSCAN : la connectivité des cœurs percole trop tôt


05

Applications : LiDAR 3D et 4D, sans apprentissage



La hiérarchie devient un espace de résolution

- ▶ L'arbre hiérarchique n'est pas qu'une sortie :
on peut y **injecter des *a priori*** géométriques
- ▶ **Détection d'anomalies 3D** : comparaison au modèle théorique du navire
- ▶ Banc d'essai sur 2×10^6 points : objets **parfaitement isolés**, sans aucun apprentissage



Modèle de référence en rouge, anomalies en couleurs
[AYANA RA 25]
© Naval Group

[AYANA RA 25] Équipe-projet AYANA, « 3D LiDAR Instance Segmentation with Geometric Priors : The HGP-Clusterer », *Rapport annuel d'activité Inria 2025*, § 7.7, fig. 8, publié en 2026.

Panoptique 4D : des *a priori* plutôt que des annotations

- ▶ État de l'art : sémantique profonde + regroupement spatial [Sautier 25] [Oh 25]
- ▶ Nos *a priori* faibles : volumes attendus des objets (véhicules, piétons) injectés dans la hiérarchie
- ▶ Association temporelle par **transport optimal** déséquilibré + filtre de KALMAN, sans apprentissage



A priori géométriques appliqués aux volumes des instances


[Sautier 25] C. Sautier *et al.*, « Alpine : is clustering enough for LiDAR instance segmentation ? », 2025.

[Oh 25] M. Oh *et al.*, « Geo-4D : training-free global geometric association for 4D LiDAR panoptic segmentation », 2025.




Résultats sur SemanticKITTI (200 trames)

Vérité terrain



Notre algorithme



Suivi des instances : aucun apprentissage, ni pour le regroupement ni pour l'association

06

Vers des données davantage structurées







Quand la structure n'est plus (seulement) la géométrie

Deux terrains d'exploration, deux mêmes idées :

- 1) les interactions d'ordre supérieur apportent la robustesse ;
- 2) la percolation gouverne les performances



Graphes signés : les liens *créent* les communautés
[Asilomar 25]




Images : extraire des réseaux de fissures [EUVIP 26]
© Cerema

[Asilomar 25] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs », Asilomar, 2025.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.

Un *framework* bayésien pour les graphes signés




$$X \sim \nu, \quad \Sigma \mid X \sim \mu_0, \quad W \mid (X, \Sigma) \sim Q, \quad \mu_O = \mathcal{L}(\Sigma \mid O)$$

- $W_e > 0$ encode une **attraction** ; $W_e < 0$, une **répulsion** ; $|W_e|$ mesure la force de l'interaction
- Dans le cas étudié, le canal calibré donne une loi *a posteriori* de GIBBS signée :

$$U_O(\sigma) = -\log \mu_0(\sigma \mid X) + \sum_{\substack{e=\{i,j\} \\ W_e > 0}} W_e \mathbb{I}_{\{\sigma_i \neq \sigma_j\}} + \sum_{\substack{e=\{i,j\} \\ W_e < 0}} |W_e| \mathbb{I}_{\{\sigma_i = \sigma_j\}}, \quad \mu_O(\sigma) = \frac{e^{-U_O(\sigma)}}{Z_O}$$



Un pas de Swendsen–Wang signé



$$\mathbb{P}(e \text{ gelée} \mid \sigma) = \begin{cases} 1 - e^{-|W_e|}, & e \text{ satisfaite,} \\ 0, & e \text{ non satisfaite.} \end{cases}$$

- Pour deux classes et un *a priori* uniforme, chaque composante gelée est **retournée en bloc** avec probabilité 1/2 : la transition est réversible et préserve μ_O [Swendsen–Wang 87].
- Dans la preuve, un pas depuis Σ produit une **réplique couplée de la loi postérieure** $\Sigma^{(1)}$ — non indépendante.




Généraliser Swendsen–Wang aux interactions d'ordre supérieur

$$U_O(\sigma) = U_0(\sigma) + \sum_{b \in \mathcal{B}} U_b(\sigma), \quad b = \text{arête, triangle, clique...}$$

- ▶ Introduire un gel auxiliaire κ : pour chaque motif b , tirer conjointement un sous-lien $\omega_b \subseteq b$
- ▶ Alternner les deux lois conditionnelles exactes

$$\kappa \mid (\sigma, O) \quad \text{puis} \quad \sigma' \mid (\kappa, O)$$

- ▶ C'est un échantillonneur de GIBBS augmenté : la même loi postérieure μ_O reste **invariante**



Le choix des motifs change la **géométrie des amas gélés** — donc leur percolation — sans changer la loi ciblée [Asilomar 25] [I&I 26+]



Le recouvrement reformulé en percolation

- Sous un *a priori* i.i.d. uniforme, ov_n est la fraction correctement étiquetée après permutation optimale des étiquettes ; $\theta^{\max}$ est la masse totale des **amas gelés macroscopiques**


Borne généralisée [I&I 26+] : pour tout estimateur τ_n ,

$$ov_n(\Sigma, \tau_n) \leq \frac{1}{K} + \frac{K-1}{K} \theta^{\max} + o_{\mathbb{P}}(1)$$


recouvrement faible $\implies \theta^{\max} > 0$ (la réciproque est fausse en général)

- Les petits amas sont recoloriés au hasard : seule une composante macroscopique peut transporter une information globale
- Dans le couplage de preuve du modèle de SANKARARAMAN–BACCELLI, le pas de SWENDSEN–WANG initialisé à la vérité Σ donne exactement $\mathbb{P}(e \text{ gelée} \mid X, \Sigma) = f_{\text{in}}(r_e) - f_{\text{out}}(r_e)$: leur obstruction est retrouvée [Sankararaman–Baccelli 18]


Extraction de réseaux de fissures sur images




intensité



profondeur



similarité du graphe



squelette extrait

- Du **pixel** (filtre de FRANGI [Frangi 98]) à la **paire de pixels** (graphe de FRANGI [GRETSI 25])
- **Multimodal**, sans apprentissage : fusion des hessiennes normalisées [EUVIP 26]
- Transferts exploratoires sans réentraînement ; sortie sous forme de **graphe éditable**

[Frangi 98] A. F. Frangi, W. J. Niessen, K. L. Vincken, M. A. Viergever, « Multiscale vessel enhancement filtering », MICCAI, 1998.

[GRETSI 25] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Généralisation du filtre de Frangi pour l'extraction des réseaux de fissures », GRETSI, 2025.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.



Le graphe de Frangi : des pixels aux interactions d'ordre 2

Modalités recalées $\rightarrow$ hessiennes multiéchelles normalisées et fusionnées $\rightarrow (\lambda_1, \lambda_2, \theta)$

Cœur publié : le graphe par paires ($K = 1$) [EUVIP 26]

$$S_{ij}^{(0)} = \max_{\sigma \in \Sigma} \underbrace{S_{\text{int}}^{\sigma}}_{\text{courbure}} \underbrace{S_{\text{shape}}^{\sigma}}_{\text{élongation}} \underbrace{S_{\text{align}}^{\sigma}}_{\text{orientation}}$$

► Un sommet est un pixel candidat ; une arête relie deux voisins dont les réponses tubulaires sont **compatibles**.

► La distance pénalise aussi les sauts :

$$d_{ij} = \text{clip}_{[0;1]} \left[\rho_{ij} (1 - S_{ij}^{(0)}) \right].$$

seuillage $\rightarrow$ composantes $\rightarrow$ arbre couvrant minimal
 $\rightarrow$ centralité pondérée $\rightarrow$ squelette

Extension triangulaire en cours ($K = 2$)
 [ANS 26] [ISPRS 26+]

$K = 1$: connectivité par arêtes



$K = 2$: soutien par triangles



► Les **arêtes deviennent les objets** : deux arêtes se recollent par un triangle. Une chaîne d'arêtes sans triangle ne suffit plus à propager la connectivité : $K = 2$ freine les ponts parasites.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.

[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

[ISPRS 26+] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, article en préparation pour l'*ISPRS Journal of Photogrammetry and Remote Sensing*, 2026.

07

Perspectives : la voie hiérarchique





Le théorème d'impossibilité de Kleinberg

Soit F une règle qui associe à toute dissimilarité d sur un ensemble fini X , $|X| \geq 2$, une **partition** $F(d)$ de X .

1. **Richesse.** Toute partition P de X peut être obtenue : $\forall P, \exists d, F(d) = P$.
2. **Invariance d'échelle.** Changer d'unité ne change pas la partition : $\forall \alpha > 0, F(\alpha d) = F(d)$.
3. **Cohérence.** Si $F(d) = P$, rapprocher les points d'un même bloc de P et éloigner ceux de blocs distincts doit laisser P inchangée.

Impossibilité [Kleinberg 02] : aucune règle F ne satisfait simultanément ces trois axiomes.

Pourquoi la hiérarchie était la bonne solution

Une partition force une **échelle unique**.

Une hiérarchie rend **toutes les partitions emboîtées** : $T(d) = \{\theta_d(r)\}_{r \geq 0}$, avec
 $r \leq r' \Rightarrow \theta_d(r) \preceq \theta_d(r')$.

- ▶ On ne demande plus à l'algorithme de choisir arbitrairement une coupe : la résolution r reste visible dans la sortie.
- ▶ Un changement d'unité **reparamètre** l'arbre au lieu de l'effacer : $\theta_{\alpha d}(r) = \theta_d(r/\alpha)$; sa structure emboîtée est préservée.
- ▶ Le théorème n'est pas contredit : on **change l'objet cible**. Pour les méthodes hiérarchiques à sortie ultramétrique, des axiomes adaptés caractérisent alors le **Single-Linkage** [Carlsson–Mémoli 10].

[Kleinberg 02] J. Kleinberg, « An impossibility theorem for clustering », *NeurIPS*, 2002.

[Carlsson–Mémoli 10] G. Carlsson, F. Mémoli, « Characterization, stability and convergence of hierarchical clustering methods », *JMLR*, 2010.

La chaîne continue : du recouvrement aux polyèdres




- Un cran plus loin [Culbertson 18] : remplacer la partition par un **recouvrement**. Pour $K \geq 2$, les K -polyèdres peuvent partager des sommets : leurs réalisations géométriques se **chevauchent** [ANS 26] — la parenté est d'idée, non de théorème
- Un nœud ne porte pas qu'un sac de points : il porte un recollement de **facettes**, c'est-à-dire une partition des $(K - 1)$ -simplexes

Deux acquis exportables : des **polyèdres**, et surtout une **hiérarchie**

[Culbertson 18] J. Culbertson, D. P. Guralnik, P. F. Stiller, « Functorial hierarchical clustering with overlaps », *Discrete Applied Mathematics*, 2018.


Au-delà de Swendsen–Wang : triangles et hiérarchie



- Numériquement, le gel corrélé par triangles retarde la percolation sur la grille triangulaire : $p_c^{\text{edge}} \simeq 0,674 \rightarrow p_c^{\Delta} \simeq 0,719$ [I&I 26+]; les **horloges** ajoutent ensuite une échelle continue aux amas gelés
- Chaque arête satisfaite reçoit $\xi_e \sim \text{Exp}(|W_e|)$; les composantes de $\{e : \xi_e \leq \beta\}$ sont emboîtées et chaque coupe β définit une dynamique invariante [I&I 26+]



Un manque : aucun modèle de fondation ne fait consensus en 3D



- ▶ Le langage [GPT-3 20] et l'image [SAM 2 24] ont chacun une **unité de calcul stable**
- ▶ En 3D, l'effort est réel — Sonata [Sonata 25], Concerto [Concerto 25], Utonia [Utonia 26] — mais il porte sur des **points** ou des voxels, et rien, à ma connaissance, ne fait encore **consensus**

[GPT-3 20] T. Brown *et al.*, « Language models are few-shot learners », *NeurIPS*, 2020.


[Sonata 25] X. Wu *et al.*, « Sonata : self-supervised learning of reliable point representations », *CVPR*, 2025.

[Concerto 25] Y. Zhang *et al.*, « Concerto : joint 2D–3D self-supervised learning emerges spatial representations », *NeurIPS*, 2025.

[Utonia 26] Y. Zhang *et al.*, « Utonia : toward one encoder for all point clouds », 2026.



Un verrou : le nuage de points est un artefact du capteur




- ▶ **Discrétisation** dictée par le capteur : nappes de balayage, résolution angulaire, rémission
- ▶ **Densité** qui décroît avec la portée : le même objet donne deux nuages incomparables
- ▶ **Occultations** : ce qui manque n'est pas vide, il est *non observé*
- ▶ Un modèle point par point apprend donc *en même temps* la géométrie, le capteur, la densité, l'occultation et la sémantique

Hypothèse assumée : c'est *une* raison centrale de la difficulté — pas la seule



La piste : le polyèdre comme alphabet, l'arbre comme grammaire




- **Chaque** nœud porte une surface *explicite* et un niveau physique : les hiérarchies de régions [SPT 23] n'agrègent que des points, et [PolyhedronNet 25] a la surface mais pas la hiérarchie
- Le niveau de la filtration est une grandeur **physique** — un rayon, en mètres, et non un indice $0, 1, 2, \dots$: les branches deviennent des trajectoires, les fusions des événements
- La *forme* se normalise — par **similitude** : ce n'est pas encore une robustesse à la portée — et taille, pose et acquisition restent des canaux séparés

[SPT 23] D. Robert, H. Raguét, L. Landrieu, « Efficient 3D semantic segmentation with Superpoint Transformer », *ICCV*, 2023.

[PolyhedronNet 25] D. Yu, G. Zhang, L. Zhao, « PolyhedronNet : representation learning for polyhedra with surface-attributed graph », *ICLR*, 2025.



Guider SAM par la hiérarchie : ce que la contre-épreuve apprend



- ▶ Une fissure se reconnaît d'abord par sa **connexité** : introduire un *a priori* de chemin dans SAM reste une hypothèse naturelle.
- ▶ Notre transposition directe de HSA est écartée : sa contrainte de blocs égalise des coefficients — elle **comprime** l'attention au lieu de l'informer [HSA 25].
- ▶ La hiérarchie doit donc **guider** le modèle — par des invites ou un biais résiduel — sans imposer l'égalité de ses coefficients d'attention.

Résultat structurel, non-gain de segmentation : aucune IoU sur SAM n'a encore été mesurée.



Une suite simple, progressive et réfutable

1. **Test idéalisé sur SAM 2 gelé.** Injecter d'abord la vérité terrain dans l'interface choisie pour vérifier si la hiérarchie offre seulement une marge. La vérité terrain à l'inférence en fait un **diagnostic**, jamais un résultat publiable.
2. **Utiliser d'abord l'interface native.** Transformer la hiérarchie en invites ponctuelles, sélectionnées par centralité de l'arbre couvrant minimal, du grossier au fin.
3. **Seulement si le signal est causal.** Apprendre un biais additif résiduel selon la distance dans le graphe ou l'arbre, initialisé à zéro : **informer** l'attention sans lier ses coefficients.

À chaque étape : **aligné contre permuté et aléatoire**, à capacité et budget identiques.
Sans séparation, on arrête.

[SAM 2 24] N. Ravi et al., « SAM 2 : segment anything in images and videos », 2024.

[HSA 25] S. Amizadeh, S. Abdali, Y. Li, K. Koishida, « Hierarchical self-attention : generalizing neural attention mechanics to multi-scale problems », *NeurIPS*, 2025.

08

Conclusion





Deux piliers, quatre contributions

1) Quand les relations binaires sont insuffisantes ou instables, les **interactions d'ordre supérieur** apportent une cohérence robuste.

2) La **percolation** est la clef de voûte théorique pour quantifier les performances de ces algorithmes.

- ▶ Une **vue unifiée** du *Single-Linkage* : heuristique (arbre couvrant), géométrie (percolation), statistique (HARTIGAN) ; applications LiDAR 3D et 4D sans apprentissage
- ▶ **HGP-Clusterer** : la hiérarchie K -NN *exacte*, via Čech, GABRIEL et la mosaïque de DELAUNAY d'ordre K [EUSIPCO 24] [CN 24] [ANS 26]
- ▶ La **vitesse de percolation** : une mesure quantitative qui explique l'échec de Robust SL et (H)DBSCAN et les gains observés des K -polyèdres dans ce protocole [SIGMETRICS SRC 24]
- ▶ L'**export du paradigme** : graphes signés (dynamiques d'ordre supérieur et bornes de recouvrement) [Asilomar 25] [I&I 26+] ; imagerie (graphe de FRANGI multimodal) [GRETSI 25] [EUVIP 26]



Perspectives, dans le fil de la thèse

- ▶ **Réduction de dimension d'ordre supérieur** : la mosaïque de DELAUNAY d'ordre K est bien plus riche que les graphes de voisinage (UMAP) : la piste privilégiée à court terme
- ▶ **Question ouverte assumée** : HGP-Clusterer n'est que *fractionnellement* consistant ; un algorithme consistant en dimension $p \geq 2$ reste à inventer
- ▶ **Graphes signés** : couplage à deux répliques pour des seuils exacts de recouvrement ; vers un algorithme pratique de détection de communautés
- ▶ **Fissures** : un logiciel d'aide à l'annotation experte fondé sur les graphes ; réconcilier modèles géométriques et apprentissage profond
- ▶ **Et, plus loin** : la *voie hiérarchique* qui précède — faire du polyèdre et de son espace d'échelle l'unité de calcul d'un modèle appris pour la 3D

Publications

Journal

- ▶ **[ANS 26]** *Generalization of Single-Linkage with higher-order interactions*, *Applied Network Science*, 2026

Conférences internationales et nationales

- ▶ **[CN 23]** Filaments de galaxies, Complex Networks, Menton, 2023
- ▶ **[EUSIPCO 24]** Hypergraphes pour le *clustering* par densité, EUSIPCO, Lyon, 2024
- ▶ **[CN 24]** Hypergraphes, percolation et *clustering* hiérarchique, Complex Networks, Istanbul, 2024
- ▶ **[SIGMETRICS SRC 24]** Mesure théorique de performance, ACM SIGMETRICS SRC, Venise, 2024 (**2^e prix**)
- ▶ **[Asilomar 25]** Dynamiques d'amas d'ordre supérieur, Asilomar, 2025
- ▶ **[GRETSI 25]** Généralisation du filtre de Frangi, GRETSI, Strasbourg, 2025
- ▶ **[EUVIP 26]** Extraction multimodale de fissures sans apprentissage, EUVIP, Luxembourg, 2026

En cours

- ▶ **[I&I 26+]** Cadre bayésien pour la détection de communautés sur graphes signés (journal)
- ▶ **[ISPRS 26+]** Graphe de Frangi généralisé, multimodal et sans apprentissage (journal ISPRS)

Logiciel : dépôts GitHub Ayana-Inria/HypergraphPercol_K2 et Ayana-Inria/Frangi-EUVIP

Merci.





Travaux de l'auteur présentés aujourd'hui

- ▶ **[HAL 17]** L. Hauseux (encadré par B. Błaszczyszyn), « Un classificateur non supervisé utilisant les complexes simpliciaux », Inria Paris, 2017. HAL : hal-01597846.
- ▶ **[CN 23]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Graph based approach for galaxy filament extraction », *Complex Networks & Their Applications*, Menton, 2023.
- ▶ **[EUSIPCO 24]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Benefits of hypergraphs for density-based clustering », *EUSIPCO*, Lyon, 2024.
- ▶ **[CN 24]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Hypergraphs, percolation and hierarchical clustering », *Complex Networks & Their Applications*, Istanbul, 2024.
- ▶ **[SIGMETRICS SRC 24]** L. Hauseux, « How can we theoretically measure the performance of density-based clustering algorithms ? », ACM SIGMETRICS SRC, Venise, 2024 (2^e prix).
- ▶ **[ANS 26]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.
- ▶ **[GRETSI 25]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Généralisation du filtre de Frangi pour l'extraction des réseaux de fissures », GRETSI, 2025.
- ▶ **[Asilomar 25]** L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs », Asilomar, 2025.
- ▶ **[EUVIP 26]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.
- ▶ **[I&I 26+]** L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article de journal en cours de rédaction, 2026.
- ▶ **[ISPRS 26+]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, article en préparation pour l'*ISPRS Journal of Photogrammetry and Remote Sensing*, 2026.



Bibliographie (1/2)

- ▶ [Florek 51] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, S. Zubrzycki, « Sur la liaison et la division des points d'un ensemble fini », Colloq. Math., 1951.
- ▶ [Gower–Ross 69] J. C. Gower, G. J. S. Ross, « Minimum spanning trees and Single-Linkage cluster analysis », JRSS C, 1969.
- ▶ [Hartigan 81] J. A. Hartigan, « Consistency of Single Linkage for high-density clusters », JASA, 1981.
- ▶ [Biau–Devroye 15] G. Biau, L. Devroye, *Lectures on the Nearest Neighbor Method*, Springer, 2015.
- ▶ [Forina 83] M. Forina, C. Armanino, S. Lanteri, E. Tiscornia, « Classification of olive oils from their fatty acid composition », 1983 (jeu de données).
- ▶ [Swendsen–Wang 87] R. H. Swendsen, J.-S. Wang, « Nonuniversal critical dynamics in Monte Carlo simulations », *Physical Review Letters*, 1987.
- ▶ [Ester 96] M. Ester, H.-P. Kriegel, J. Sander, X. Xu, « A density-based algorithm for discovering clusters » (DBSCAN), KDD, 1996.
- ▶ [Frangi 98] A. F. Frangi, W. J. Niessen, K. L. Vincken, M. A. Viergever, « Multiscale vessel enhancement filtering », MICCAI, 1998.
- ▶ [Kleinberg 02] J. Kleinberg, « An impossibility theorem for clustering », *NeurIPS*, 2002.
- ▶ [Penrose 03] M. Penrose, *Random Geometric Graphs*, Oxford University Press, 2003.
- ▶ [Ghrist 08] R. Ghrist, « Barcodes : the persistent topology of data », Bulletin of the AMS, 2008.
- ▶ [Chaudhuri–Dasgupta 10] K. Chaudhuri, S. Dasgupta, « Rates of convergence for the cluster tree », *NeurIPS*, 2010.
- ▶ [Carlsson–Mémoli 10] G. Carlsson, F. Mémoli, « Characterization, stability and convergence of hierarchical clustering methods », JMLR, 2010.
- ▶ [Campello 13] R. Campello, D. Moulavi, J. Sander, « Density-based clustering based on hierarchical density estimates » (HDBSCAN), PAKDD, 2013.



Bibliographie (2/2)


- ▶ [Boissonnat 18] J.-D. Boissonnat, F. Chazal, M. Yvinec, *Geometric and Topological Inference*, Cambridge University Press, 2018.
- ▶ [Culbertson 18] J. Culbertson, D. P. Guralnik, P. F. Stiller, « Functorial hierarchical clustering with overlaps », *Discrete Applied Mathematics*, 2018.
- ▶ [Sankararaman–Baccelli 18] A. Sankararaman, F. Baccelli, « Community detection on Euclidean random graphs », *ACM–SIAM SODA*, 2018.
- ▶ [GPT-3 20] T. Brown *et al.*, « Language models are few-shot learners », *NeurIPS*, 2020.
- ▶ [Edelsbrunner–Osang 23] H. Edelsbrunner, G. Osang, « A simple algorithm for higher-order Delaunay mosaics and alpha shapes », *Algorithmica*, 2023.
- ▶ [SPT 23] D. Robert, H. Raguét, L. Landrieu, « Efficient 3D semantic segmentation with Superpoint Transformer », *ICCV*, 2023.
- ▶ [Rolle–Scoccola 23] A. Rolle, L. Scoccola, « Stable and consistent density-based clustering » (Persistable), *JMLR*, 2024.
- ▶ [SAM 2 24] N. Ravi *et al.*, « SAM 2 : segment anything in images and videos », 2024.
- ▶ [Sautier 25] C. Sautier *et al.*, « Alpine : is clustering enough for LiDAR instance segmentation ? », 2025.
- ▶ [Oh 25] M. Oh *et al.*, « Geo-4D : training-free global geometric association for 4D LiDAR panoptic segmentation », 2025.
- ▶ [Sonata 25] X. Wu *et al.*, « Sonata : self-supervised learning of reliable point representations », *CVPR*, 2025.
- ▶ [Concerto 25] Y. Zhang *et al.*, « Concerto : joint 2D–3D self-supervised learning emerges spatial representations », *NeurIPS*, 2025.
- ▶ [PolyhedronNet 25] D. Yu, G. Zhang, L. Zhao, « PolyhedronNet : representation learning for polyhedra with surface-attributed graph », *ICLR*, 2025.
- ▶ [HSA 25] S. Amizadeh, S. Abdali, Y. Li, K. Koishida, « Hierarchical self-attention : generalizing neural attention mechanics to multi-scale problems », *NeurIPS*, 2025.
- ▶ [Utonia 26] Y. Zhang *et al.*, « Utonia : toward one encoder for all point clouds », 2026.

Diapositives de secours






Stylométrie 2017 : le cas à 5 auteurs



- ▶ 5 auteurs $\times$ 40 textes ($P = 70\%$, $k = 5$)
- ▶ 4 classes correctement identifiées...
- ▶ ... mais la 4^e (textes 120–159) est manquée
- ▶ Ronds noirs : non classés ; étoiles : affectés à plusieurs classes



Banc d'essai SIPU : toutes choses égales par ailleurs



Même $\text{min_cluster_size} = \sqrt{n}$, même excès de masse :
la seule différence est la **connexité triangulaire**

Jeu	HDBSCAN	2-polyèdres
a2	0,762	0,834
a3	0,696	0,831
d31	0,660	0,835
s2	0,780	0,842
s3	0,251	0,418
birch2	0,996	0,998

RI ; grille : vérité, HDBSCAN, notre algorithme



Huiles d'olive : la matrice de confusion

Pers./Ours	1	2	3	4	5	6	7	8	9	Miss.
N. Apulia	12/24	0/0	0/0	-	0/0	0/0	0/0	0/0	0/0	13/1
Calabria	0/0	7/25	1/2	-	0/0	0/0	0/0	0/0	0/0	48/29
S. Apulia	0/0	0/0	100/145	-	0/0	0/0	0/0	0/0	0/0	106/61
Sicilia	3/6	0/1	0/2	-	0/0	0/0	0/0	0/0	0/0	33/27
Inl. Sard.	0/0	0/0	0/0	-	51/62	0/0	0/0	0/0	0/0	14/3
Coast S.	0/0	0/0	0/0	-	0/2	19/29	0/0	0/0	0/0	14/2
E. Ligur.	0/0	0/0	0/0	-	0/0	0/0	14/32	1/2	0/1	35/15
W. Ligur.	0/0	0/0	0/0	-	0/0	0/0	0/0	29/33	0/0	21/17
Umbria	0/0	0/0	0/0	-	0/0	0/0	0/0	0/0	42/46	9/5

- ▶ 412/572 points classés (72 %), dont 96,1 % correctement
- ▶ Persistable [Rolle–Scoccola 23] : 49 % classés seulement
- ▶ En partition exhaustive : ARI 0,890 contre 0,848




Vitesses de percolation : le protocole

- ▶ $\mathcal{X}$: $n = 100\,000$ points uniformes dans $\left[0; n^{1/p}\right]^p$ ($n = 10\,000$ en dimension 4)
- ▶ $T = 100$ tirages indépendants ; rappel $\varepsilon = 3\%$
- ▶ Pour chaque algorithme (HGP, Robust SL, DBSCAN) : rayons de fusion et taille de la plus grande composante
- ▶ Estimateur $\hat{v} = \hat{\lambda}_\varepsilon / \hat{\lambda}_{1-\varepsilon}$
- ▶ Repère : seuil critique du modèle booléen ($K = 1$, 2D) : $\lambda_c \approx 1,44$




Vitesses de percolation : *Robust Single-Linkage* et DBSCAN



Robust Single-Linkage : la percolation converge trop lentement vers

1



DBSCAN : la frontière est réintégrée, mais les cœurs percolent trop

tôt




Quand $K \rightarrow +\infty$: la fenêtre gaussienne


- ▶ Dans la fenêtre $\mu = K + a\sqrt{K}$, les niveaux K -NN convergent vers les **excursions** $E_a = \{G_p \geq -a\}$ d'un champ gaussien
- ▶ Covariance du champ : le volume d'intersection de deux boules
- ▶ Les trois algorithmes ne diffèrent que par l'**ordre des opérations** : dilater puis connecter (cœurs, DBSCAN) vs. connecter puis dilater (polyèdres)
- ▶ Seuils de bruit : $a_c^{\text{poly}} \geq a_c^{\text{core}}$, vitesse asymptotiquement meilleure pour les K -polyèdres



L'état de l'art LiDAR



Alpine [Sautier 25] : « *Is clustering enough ?* »



Geo-4D [Oh 25] : association géométrique 4D




L'assemblage d'haplotypes

Un graphe signé bruité


Nœuds = lectures ADN ; arêtes = chevauchements (attractions et répulsions)

But : retrouver l'affectation cachée Σ





Le cadre bayésien et l'hypothèse de Gibbs



$$U(\sigma) = \sum_{e \in F} W_e \mathbb{I}_{\{\sigma_i \neq \sigma_j\}} + \sum_{e \in \tilde{F}} |W_e| \mathbb{I}_{\{\sigma_i = \sigma_j\}} \quad \mu_{X,W}(\sigma) = \frac{e^{-U(\sigma)}}{Z}$$

- ▶ F : arêtes attractives ($W_e > 0$); $\tilde{F}$: répulsives ($W_e < 0$); U pénalise les arêtes insatisfaites
- ▶ **Hypothèse de Gibbs** : la loi *a posteriori* est la mesure de Gibbs signée



Un pas de Swendsen–Wang signé, en détail

- ▶ **Gel** : chaque arête *satisfaite* est gelée avec probabilité $1 - e^{-|W_e|}$; les insatisfaites jamais
- ▶ **Recoloriage** : chaque amas gelé est recolorié uniformément au hasard
- ▶ La dynamique laisse la loi *a posteriori* invariante
- ▶ Un pas depuis la vérité Σ produit une **réplique** $\Sigma^{(1)} \sim \mu_{X,W}$ (identité de Nishimori) : un couplage entre vérité et observation
- ▶ Les petits amas sont recoloriés aveuglément : l'information globale ne survit que dans les **composantes géantes**



Le modèle de Sankararaman–Bacelli, en détail

- ▶ Nœuds : processus de Poisson dans $\mathbb{R}^p$; communautés $\Sigma_i \in \{\pm 1\}$ uniformes
- ▶ Arête $e = \{i, j\}$ présente avec probabilité $f_{\text{in}}(r_e)$ (même communauté) ou $f_{\text{out}}(r_e)$ (communautés différentes), $r_e = \|X_i - X_j\|$
- ▶ Poids signés reconstruits : $W_e = \log \frac{f_{\text{in}}(r_e)}{f_{\text{out}}(r_e)} \geq 0$ si e observée, $W_e = -\log \frac{1-f_{\text{out}}(r_e)}{1-f_{\text{in}}(r_e)} \leq 0$ sinon

$$\mathbb{P}(\text{arête gelée}) = f_{\text{in}}(r_e) \left(1 - e^{-|W_e|}\right) = f_{\text{in}}(r_e) - f_{\text{out}}(r_e)$$

- ▶ Le graphe gelé d'un pas de SW sur les arêtes est **exactement** la percolation indépendante de [Sankararaman–Bacelli 18]




La hiérarchie d'horloges, en détail

- ▶ Conditionnellement à $\sigma : \xi_e \sim \text{Exp}(|W_e|)$ sur les arêtes satisfaites, $\xi_e = +\infty$ sinon ; $\Pi_\beta =$ composantes de $\{\xi_e \leq \beta\}$; le dendrogramme s'obtient par KRUSKAL
- ▶ $\mathbb{P}(\xi_e \leq 1) = 1 - e^{-|W_e|}$: Π_1 est **exactement** la partition gelée de Swendsen–Wang
- ▶ Mesure jointe de type EDWARDS–SOKAL $\nu(\sigma, D)$; à chaque nœud, un **bain thermique exact** sur les quatre orientations relatives des deux fils (balance détaillée, invariance)
- ▶ Le dendrogramme est **non marqué** : l'identité de l'arête gagnante est marginalisée — une fusion dépend de toute la coupe $\Lambda_u(\sigma) = \sum_{e \in E_u} |W_e| \mathbb{I}_{\{e \text{ satisfaite}\}}$
- ▶ Sur le tore triangulaire : Π_t suit une percolation indépendante $q_p(t) = p(1 - e^{-u_p t})$,
 $u_p = \log \frac{p}{1-p}$




L'échelle des seuils du GSBM triangulaire



- Gel SW $0,6736 < \text{triangles } 0,7192 < \text{percolation de l'information } 0,7947 < \text{record rigoureux } 0,8094$
- Point multicritique de Nishimori $0,8358$: conjecture




Calibration exacte sur le SBM



- ▶ Deux répliques, deux dendrogrammes **indépendants**, coupés au même β_c
- ▶ Chaque arête transmet exactement θ^2 : calibration $\beta_X = \beta_c \Leftrightarrow d\theta^2 = 1$ (le seuil de KESTEN-STIGUM)
- ▶ Quand le signal diverge, $\beta_{c,n} \rightarrow 0$: la coupe s'écrase d'elle-même sur Glauber




Validation à 10^6 nœuds : les trois régimes



$p = 0,70$: seules les arêtes standard percolent ; l'*overlap* reste au bruit




Validation à 10^6 nœuds : les trois régimes



$p = 0,72$: toutes les dynamiques percolent... mais l'*overlap* reste au bruit (nécessaire $\neq$ suffisant)




Validation à 10^6 nœuds : les trois régimes



$p = 0,80$: composantes géantes stables et **recouvrement effectif**





VT-GraF : la connexité $K = 2$ sur le terrain



- ▶ Visible granulaire + thermique : la réponse de Frangi seule est noyée dans les cailloux
- ▶ Les composantes triangles-connexes éliminent les artefacts granulaires



Sans entraînement... et robuste




Sous bruit croissant, notre méthode (rouge) reste stable

Vaches Noires : vérité (vert), nous (rouge), U-Net (bleu)


- ▶ Compétitif avec un U-Net ayant coûté deux jours d'annotation experte
- ▶ CrackSegDiff : 87 % vs. 63 % de Jaccard sur données propres... mais s'effondre hors distribution



Transferts sans réentraînement




Palais des Papes : la fracture principale



CrackForest : Jaccard 78 %, Wasserstein 5 px




Sensibilité aux paramètres




Seuil relatif τ : optimum net vers $\tau \approx 0,2$ (graphe fragmenté vs. ponts parasites)



CrackSAM-GeoLoRA : le protocole causal



Six variantes, IoU stricte sur 1 695 images de test (corpus Khánh Hà)



Évidence alignée vs. permutée : sur la diagonale

- ▶ Valeur de référence 0,6241 ; perte tolérante 0,6276 ; géométrie + tolérance 0,6270 $\approx$ évidence permutée 0,6265
- ▶ $|\Delta| < 0,001$ à toutes les tolérances : en monomodal, la géométrie n'apporte pas d'information nouvelle




Rester honnête : ce qui reste entièrement à démontrer



Le mot « **modèle de fondation** » n'est pas revendiqué :
il désigne ici le point d'arrivée d'un programme de **réfutation**, pas un résultat

- L'**alphabet** existe — les polyèdres et leur hiérarchie, c'est la thèse ; le code qui en ferait des jetons reste à choisir, le **modèle** n'est pas écrit et aucune expérience d'apprentissage n'a été menée
- Si l'arbre réel ne bat ni le modèle plat, ni un arbre aléatoire, ni un arbre octal, le pari hiérarchique tombe
- La marge attendue concerne les objets **filiformes** ; or la connexité d'ordre K les fait naître *tard* dans la filtration

Voie hiérarchique : ce que la thèse fournit déjà



Le pari : l'**alphabet** est déjà là ; le code et le modèle restent à écrire


- Ce que la hiérarchie sérialise pour chaque nœud : la surface (facettes, aires, normales, bords), le niveau de naissance, le parent, les enfants de fusion, les voisins latéraux et la confiance d'acquisition
- L'interface vers les points existe déjà : le vote pondéré $w_{x\tau} = S_\tau / T_x$ du § 9.1, partition de l'unité sur les points couverts ($T_x > 0$)
- Ce qui manque est en aval : encodeur de surface, encodeur de branche, encodeur de fusion, décodeur par facette — et les campagnes qui les jugeraient



Voie hiérarchique : pourquoi le résultat négatif est structurel



ce que HSA exige
arité $b \simeq 8$, profondeur $\log_b N \simeq 4,5$



ce que donne le graphe de Frangi
arité $b \simeq 1,3$, profondeur 358

une fissure est une chenille : 72 % des nœuds internes n'ont qu'un seul enfant

- **Surface d'attaque** : 3 blocs d'attention globale sur 48 dans Hiera-L, soit 6,56 % des opérations du tronc
- **Forme de l'arbre** : ce n'est pas un réglage — l'arité $b = (N - 1)/(N - L)$ est *fixée* par la fraction de feuilles, donc par la géométrie de la fissure
- Ce défaut-là se répare (décomposition en centroïdes de l'arbre couvrant minimal *non élagué*, sur la grille 64×64 : profondeur 12, arité 2,82) ; ce qui ne se répare pas, c'est qu'une contrainte de blocs *comprime* au lieu d'informer
- **Limite assumée** : mesures sur fissures *synthétiques* calibrées sur le corpus Khánh Hà (448 px, largeur 19 px, couverture 5,7 %)



Voie hiérarchique : comment saurais-je que c'est l'arbre qui aide ?

Bras	Structure
H0	polyèdres indépendants
H1	graphe latéral seulement
H2	arbre aléatoire apparié (profondeur, degrés, masses)
H3	arbre octal ou arbre de voxels
H4	HDBSCAN ou Robust SL
H5	niveaux HGP permutés
H6	topologie HGP sans les niveaux
H7	trajectoires HGP complètes
H8	H7 + événements + latéral

À segmentation en jetons, paramètres et budget **appariés**, trois lectures suffisent à réfuter le pari :

- ▶ $H6 \approx H7$: les **niveaux** de densité n'apportent rien
- ▶ $H4 \approx H7$: une hiérarchie **générique** suffit
- ▶ $H1 \approx H8$: le **graphe spatial** explique tout

Ces résultats resteraient publiables comme **réfutation**
— mais pas sous le *claim* prévu.



Voie hiérarchique : efficacité *contre* continuité, en chiffres

Hiérarchie candidate	Profondeur	Arité	Dilution à longue portée
sémantique {fissure, fond}	10,3	3,17	181
<i>son contrôle permuté</i>	10,0	3,23	808
coupe spatiale <i>min-cut</i>	9,3	2,75	768
ordonné le long de la fissure	10,0	2,66	1 024
FRANGI + centroïdes	12,0	2,82	1 013
<i>quadtree</i>	7,0	4,00	1 024
aléatoire	7,0	4,00	1 024

- ▶ **Dilution** : combien de jetons sont moyennés avec j quand i l'attend. Sous attention plate, elle vaut 1 — 181 reste donc *énorme*. Médianes sur **trois fissures synthétiques**
- ▶ L'écart 181 contre 808 mesure la **causalité** (bon masque vs. masque d'une autre image), pas une performance : aucun IoU n'a été mesuré
- ▶ Toutes les hiérarchies **équilibrées** plafonnent entre 768 et 1 024, y compris celle qui cherche explicitement à éviter la fissure