

# Utilisation de graphes pour la classification et l'extraction de structures

Généralisation à des interactions d'ordre supérieur



Soutenance de thèse, mardi 8 septembre 2026

Learning Centre SophiaTech, Université Côte d'Azur

Louis HAUSEUX (Centre Inria d'Université Côte d'Azur ; bourse 3IA-DS4H)

Thèse dirigée par Konstantin AVRACHENKOV (NEO) et co-encadrée par Josiane ZERUBIA (AYANA)

Rapporteurs : Dieter MITSCHKE (PUC de Chile), Hocine CHERIFI (Univ. de Bourgogne)

Examineurs : Nicolas NISSE (Inria), Pierre CHARBONNIER (Cerema), Zoltan KATO (Univ. de Szeged)

# 01

## Prologue : une ancienne énigme





## Une ancienne énigme...

Un classificateur non-supervisé utilisant les  
*complexes simpliciaux*  
(avec une application à la *stylométrie*).

LOUIS HAUSEUX  
Encadré par BARTŁOMIEJ BŁASZCZYSZYN



juillet 2017

Avant-propos

Stage à l'Inria Paris, équipe DYOGENE-MATHNET [HAL 17]

[HAL 17] L. Hauseux (encadré par B. Błaszczyszyn), « Un classificateur non-supervisé utilisant les complexes simpliciaux », Inria Paris, 2017. HAL : hal-01597846.

# Le sujet à la mode : l'homologie *persistante*




Faire croître un rayon  $r$  ; regarder les structures **naître, vivre, mourir** [Ghrist 08]





## ...avec une application à la *stylométrie*




- ▶ Une matrice de **Gram** : similarité  $500 \times 500$  entre articles de presse
- ▶ **5 auteurs** anonymes, 100 articles chacun (statistiques de style : vocabulaire, catégories grammaticales, ponctuation, etc.)
- ▶ **But (non supervisé)** : rendre à chaque auteur ses 100 articles

Ici, les articles sont *triés* par auteur : les 5 blocs diagonaux sautent aux yeux... mais l'algorithme ne voit qu'une matrice mélangée



## Une heuristique inspirée de la persistance




- Faire croître le seuil de similarité
- Observer les composantes « **triangles-connexes** »  
(des  $k$ -simplexes recollés par facettes)
- Les voir **naître, grandir, fusionner**
- S'arrêter : une proportion  $P$  est couverte

Les « polyèdres » retournés ( $k = 2$ ) [HAL 17]



## Et... cela marche bien



- ▶ **2 auteurs** : 1 erreur, 1 non-classé (sur 100)
- ▶ Mieux que le  $K$ -Means...
- ▶ ... et que des mélanges gaussiens *semi-supervisés*
- ▶ Et sur **5 auteurs** : 4 clusters retrouvés

# Pourquoi cela marche-t-il si bien ?



# Plan

- I) Prologue : une ancienne énigme
- II) Du Single-Linkage à ses fondements
- III) Monter à l'**ordre supérieur** : la hiérarchie  $K$ -NN exacte
- IV) La **percolation** comme mesure de performance
- V) Applications : LiDAR 3D/4D, sans apprentissage
- VI) Vers des données davantage structurées
- VII) Perspectives : la voie **hiérarchique**
- VIII) Conclusion


# 02

## Du Single-Linkage à ses fondements



# Le clustering sur données euclidiennes $\mathcal{X} \subset \mathbb{R}^p$

## Modèle de Hartigan [Hartigan 81] : les amas de forte densité




[Hartigan 81] J. A. Hartigan, « Consistency of Single Linkage for high-density clusters », JASA, 1981.


[Campello 13] R. Campello, D. Moulavi, J. Sander, « Density-based clustering based on hierarchical density estimates » (HDBSCAN), PAKDD, 2013.



## Deux exemples issus de la thèse



Cosmologie 3D : filaments de galaxies [CN 23]



Huiles d'olive ( $\mathbb{R}^8$ ) : hiérarchie obtenue [ANS 26]

[CN 23] L. Hauseux, K. Avrachenkov, J. Zerubia, « Graph based approach for galaxy filament extraction », *Complex Networks & Their Applications*, Menton, 2023.


[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.



# Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau  $\{f \geq \lambda\}$

Arbre hiérarchique




$C_1$




## Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau  $\{f \geq \lambda\}$




Arbre hiérarchique




# Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau  $\{f \geq \lambda\}$




Arbre hiérarchique




## Le modèle de Hartigan : la hiérarchie des amas

Ensemble de niveau  $\{f \geq \lambda\}$



Arbre hiérarchique





## En pratique : estimer la densité

$$\hat{f} \leftarrow \hat{f}_{K\text{-NN}}$$

Estimateur des  $K$  plus proches voisins


$$\forall x \in \mathbb{R}^p, \quad \hat{f}_{K\text{-NN}}(x) = \frac{K}{n \omega_p r_K(x)^p}$$

- ▶  $n$  : nombre de points de  $\mathcal{X}$
- ▶  $\omega_p$  : volume de la boule unité de  $\mathbb{R}^p$
- ▶  $r_K(x)$  : distance de  $x$  à son  $K^{\text{e}}$  plus proche voisin

$$r_K(x) = \min \{r \geq 0 \mid |B(x, r) \cap \mathcal{X}| \geq K\}$$




## Le cas $K = 1$ : un « miracle » géométrique





## Le cas $K = 1$ : un « miracle » géométrique




$$\hat{\lambda}(x) \geq \lambda_0$$
$$\Leftrightarrow r_1(x) \leq r_0$$

Ensembles de niveau  
= **modèle booléen**



## Le cas $K = 1$ : un « miracle » géométrique




$$\hat{\lambda}(x) \geq \lambda_0$$
$$\Leftrightarrow r_1(x) \leq r_0$$

Amas de forte densité  
= **composantes connexes**  
d'un **graphe géométrique** [Penrose 03]





## Le cas $K = 1$ : un « miracle » géométrique




$$r_1(x) \leq r_0$$

Amas de forte densité  
= **composantes connexes**  
d'un **graphe géométrique** [Penrose 03]



## Le cas $K = 1$ : un « miracle » géométrique




$$r_1(x) \leq r_0$$

Amas de forte densité  
= **composantes connexes**  
de l'**arbre minimum couvrant** élagué



# L'arbre minimum couvrant et la triangulation de Delaunay



Cette hiérarchie a un nom :  
le **Single-Linkage** [Florek 51]  
[Gower-Ross 69]

L'arbre minimum couvrant euclidien  
vit dans la triangulation de DELAUNAY  
[Boissonnat 18] :

arbre minimum couvrant  $\subseteq$  DELAUNAY


Dans le plan  $\mathbb{R}^2$  :  $\mathcal{O}(n \log n)$

[Florek 51] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, S. Zubrzycki, « Sur la liaison et la division des points d'un ensemble fini », Colloq. Math., 1951.

[Gower-Ross 69] J. C. Gower, G. J. S. Ross, « Minimum spanning trees and Single-Linkage cluster analysis », JRSS C, 1969.

[Boissonnat 18] J.-D. Boissonnat, F. Chazal, M. Yvinec, *Geometric and Topological Inference*, Cambridge University Press, 2018.

## L'effet de chaînage et le Robust Single-Linkage




**Effet de chaînage** : une chaîne de points suffit à fusionner deux amas

**Robust Single-Linkage** [Chaudhuri-Dasgupta 10] :

- ▶ La *core distance*  $r_K(x)$  estime la densité locale
- ▶ La distance devient la *mutual reachability*
- ▶ Les points isolés sont repoussés

## Les descendants : DBSCAN, puis HDBSCAN



**DBSCAN** [Ester 96] : points *cœurs* ( $r_K(x) \leq r$ ) vs. points *accessibles* : réintègre la frontière des amas

**HDBSCAN** [Campello 13] : fait varier le seuil  $r$  continûment et extrait les clusters par **excès de masse**

$$E(C) = \int_C (f(x) - \lambda) dx$$


03

## Monter à l'ordre supérieur : la hiérarchie $K$ -NN exacte




## Que font Robust SL / (H)DBSCAN pour $K = 2$ ?

Nuage de points et boules de rayon  $r$



Arbre hiérarchique obtenu




Un dendrogramme **plat** : toute l'information hiérarchique fine est perdue




## La vraie hiérarchie 2-NN : échelle $r$

Les 2-intersections de boules au niveau  $r$



Arbre hiérarchique




Étape 1 : les 7 segments fusionnent au seuil  $r$





## La vraie hiérarchie 2-NN : échelle $r'$

Triangles et 3-intersections à  $r'$



Arbre hiérarchique




Étape 2 : fusion des triangles à  $r'$  via les 3-intersections. L'arête  $CD$  reste isolée




## La vraie hiérarchie 2-NN : échelle $r''$

Connexité globale à  $r''$




Arbre hiérarchique




Étape 3 : connexité globale à  $r''$  par les points de tangence

# Le diagnostic

Robust SL ( $K = 2$ )



Vraie hiérarchie 2-NN




Une asymétrie : condition d'ordre  $K$  sur les **points**, mais connexité d'ordre 1 par les **arêtes**



# La réparation : le complexe de Čech et les $K$ -polyèdres

- ▶ **Graphe géométrique**  $\longrightarrow$  **complexe de Čech** :  
un  $K$ -simplexe =  $K + 1$  boules qui s'intersectent
- ▶ **Composantes connexes**  $\longrightarrow$   **$K$ -polyèdres** :  
des  $(K - 1)$ -simplexes recollés par des  $K$ -simplexes
- ▶ Pour  $K \geq 2$ , les clusters peuvent **se recouvrir**

**Théorème [ANS 26] [EUSIPCO 24]** : à tout niveau, les  $K$ -polyèdres identifient *exactement* les amas discrets de forte densité de l'estimateur  $\hat{f}_{K\text{-NN}}$ . Pour  $K = 1$  : le Single-Linkage




[ANS 26] L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.

[EUSIPCO 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Benefits of hypergraphs for density-based clustering », *EUSIPCO*, Lyon, 2024.


# Qui provoque les fusions ? La condition de Gabriel

Arête de l'arbre minimum couvrant  $\longrightarrow$  simplexe  $K$ -séparant

- ▶ Le simplexe  $K$ -séparant : celui qui provoque une fusion
- ▶ Cas  $K = 1$  : les 1-séparants sont exactement les arêtes de l'arbre minimum couvrant
- ▶ **Théorème [ANS 26]** : tout simplexe  $K$ -séparant est un simplexe de **Gabriel** (sa boule minimale est vide d'intrus)



Triangle de Gabriel (boule vide)



Non-Gabriel (boule non vide)



## $K$ -arbre couvrant et mosaïque de Delaunay d'ordre $K$


- ▶ **Fusions critiques** : les simplexes  $K$ -séparants, tous  $K$ -GABRIEL (boule minimale vide)
- ▶ **Arbre couvrant**  $\longrightarrow$   **$K$ -arbre couvrant** : élagué à  $r$ , il redonne les  $K$ -polyèdres [ANS 26]
- ▶ **Delaunay**  $\longrightarrow$  **mosaïque d'ordre  $K$**  : elle porte tous les simplexes  $K$ -GABRIEL [Edelsbrunner-Osang 23]
- ▶ Pour  $K = 2$  : tout se lit dans DELAUNAY, en  $\mathcal{O}(n \log n)$  dans le plan

### Analogie ordre 1 vs. ordre $K$


|                  | $K = 1$       | $K \geq 2$           |
|------------------|---------------|----------------------|
| <b>Sommets</b>   | points        | $(K - 1)$ -simplexes |
| <b>Fusions</b>   | arêtes        | $K$ -simplexes       |
| <b>Condition</b> | arête GABRIEL | $K$ -GABRIEL         |
| <b>Domaine</b>   | DELAUNAY      | DELAUNAY d'ordre $K$ |



## En pratique ( $K = 2$ ) : les huiles d'olive italiennes [Forina 83]



HDBSCAN : 3 macro-régions



2-polyèdres : 8 des 9 provinces retrouvées

Au-delà de l'état de l'art [Rolle-Scoccola 23] [ANS 26]

[Forina 83] M. Forina, C. Armanino, S. Lanteri, E. Tiscornia, « Classification of olive oils from their fatty acid composition », 1983 (jeu de données).

[Rolle-Scoccola 23] A. Rolle, L. Scoccola, « Stable and consistent density-based clustering » (Persistable), JMLR, 2024.


04

# La **percolation** comme mesure de performance





## Le phénomène au cœur de tout : la percolation continue



$$r < r_c$$


$$r = r_c$$

$$r > r_c$$

Au-delà d'un seuil critique, une **composante géante** (en rouge) émerge [Penrose 03]




## Pourquoi le Single-Linkage échoue en dimension $\geq 2$



Deux amas denses,  $A$  et  $B$  (les carrés), sur un fond de faible densité




## Pourquoi le Single-Linkage échoue en dimension $\geq 2$



Arbre couvrant élagué au rayon  $r_1$  : la percolation a lieu dans chaque carré, pas sur le fond




## Pourquoi le Single-Linkage échoue en dimension $\geq 2$



Au rayon  $r_2 > r_1$ , le fond percole aussi : A et B fusionnent *avant* d'avoir été entièrement récupérés



## La fraction récupérable




Probabilité de percolation des  $K$ -polyèdres

- En ordonnée : la fraction des points dans la **composante géante**
- Sous le seuil critique  $\lambda_c$  : rien
- La **fraction récupérable** d'un amas se lit sur la courbe



## Quantifier : la *vitesse de percolation*



Probabilité de percolation des  $K$ -polyèdres

$$v = \frac{\lambda_c}{\lambda_{1-\epsilon}}$$

- $\lambda_c$  : le fond **commence** à percoler
- $\lambda_{1-\epsilon}$  : l'amas est presque **entier**
- Plus  $v$  est **proche de 1**, meilleur est l'algorithme  
[Sigm SRC 24] [CN 24]

[Sigm SRC 24] L. Hauseux, « How can we theoretically measure the performance of density-based clustering algorithms? », ACM SIGMETRICS SRC, Venice, 2024 (2<sup>e</sup> prix).

[CN 24] L. Hauseux, K. Avrachenkov, J. Zerubia, « Hypergraphs, percolation and hierarchical clustering », *Complex Networks & Their Applications*, Istanbul, 2024.



## Vitesses de percolation mesurées

| $K$ | $p = 2$      |              |              | $p = 3$      |              |              | $p = 4$      |              |              |
|-----|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|
|     | HGP          | Robust SL    | DBSCAN       | HGP          | Robust SL    | DBSCAN       | HGP          | Robust SL    | DBSCAN       |
| 1   | <b>0,735</b> | <b>0,735</b> | <b>0,735</b> | <b>0,563</b> | <b>0,563</b> | <b>0,563</b> | <b>0,362</b> | <b>0,362</b> | <b>0,362</b> |
| 2   | <b>0,779</b> | 0,689        | 0,735        | <b>0,646</b> | 0,462        | 0,563        | <b>0,451</b> | 0,271        | 0,362        |
| 3   | <b>0,800</b> | 0,632        | 0,753        | <b>0,690</b> | 0,412        | 0,582        | <b>0,497</b> | 0,247        | 0,378        |
| 4   | <b>0,817</b> | 0,598        | 0,767        | <b>0,714</b> | 0,400        | 0,605        | <b>0,500</b> | 0,246        | 0,409        |
| 5   | <b>0,826</b> | 0,584        | 0,779        | <b>0,732</b> | 0,399        | 0,625        | <b>0,534</b> | 0,236        | 0,415        |

- ▶ Les  $K$ -polyèdres : la vitesse **croît** avec  $K$ , dans toutes les dimensions
- ▶ Robust SL : augmenter  $K$  **dégrade** (jeter la frontière est rédhibitoire)
- ▶ DBSCAN : la connectivité des cœurs percole trop tôt

05


# Applications : LiDAR 3D/4D, sans apprentissage





## La hiérarchie devient un espace de résolution

- ▶ L'arbre hiérarchique n'est pas qu'une sortie :  
on peut y **injecter des *a priori*** géométriques
- ▶ **Détection d'anomalies 3D** : comparaison au modèle théorique du navire (© NAVAL GROUP)
- ▶ Benchmark de  $2 \times 10^6$  points : objets **parfaitement isolés**, sans aucun apprentissage



Modèle de référence en rouge, anomalies en couleurs

# Panoptique 4D : des *a priori* plutôt que des annotations

- ▶ État de l'art : sémantique profonde + clustering spatial [Sautier 25] [Oh 25]
- ▶ Nos *a priori* faibles : volumes attendus des objets (véhicules, piétons) injectés dans la hiérarchie
- ▶ Association temporelle par **transport optimal** déséquilibré + filtre de KALMAN, *training-free*



*A priori* géométriques appliqués aux volumes des instances


[Sautier 25] C. Sautier & al., « Alpine : is clustering enough for LiDAR instance segmentation ? », 2025.

[Oh 25] M. Oh & al., « Geo-4D : training-free global geometric association for 4D LiDAR panoptic segmentation », 2025.




## Résultats sur SemanticKITTI (200 trames)

Vérité terrain



Notre algorithme



Suivi des instances : aucun apprentissage, ni pour le clustering ni pour l'association

# 06

## Vers des données davantage structurées







# Quand la structure n'est plus (seulement) la géométrie

Deux terrains d'exploration, deux mêmes idées :

- 1) les interactions d'ordre supérieur apportent la robustesse ;
- 2) la percolation gouverne les performances




**Graphes signés** : les liens *créent* les communautés



**Images** : extraire des réseaux de fissures

# Détection de communautés sur graphes signés



- Un **cadre bayésien** pour les graphes signés (attractions et répulsions) [Sankararaman-Bacelli 18]
- Des **dynamiques de clusters** d'ordre supérieur [Swendsen-Wang 87]
- La **percolation** des amas gelés conditionne le recouvrement :  
des bornes plus fines [Asilomar 25] [I&I 26+]


[Sankararaman-Bacelli 18] A. Sankararaman, F. Bacelli, « Community detection on Euclidean random graphs », *ACM-SIAM SODA*, 2018.

[Swendsen-Wang 87] R. H. Swendsen, J.-S. Wang, « Nonuniversal critical dynamics in Monte Carlo simulations », *Physical Review Letters*, 1987.

[Asilomar 25] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs », *Asilomar*, 2025.

[I&I 26+] L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article de journal en cours de rédaction, 2026.

## Au-delà de Swendsen–Wang : triangles et hiérarchie



- Face à la frustration, le gel **corrélé par triangles** gèle moins... et percole plus tard
- Une **hiérarchie d'horloges** : chaque arête satisfaite reçoit  $\xi_e \sim \text{Exp}(|W_e|)$  ;  
couper le dendrogramme à l'instant  $\beta$  donne une dynamique invariante
- Les **racines** ( $\beta = 1$ ) redonnent Swendsen–Wang ; les **feuilles** ( $\beta = 0$ ), Glauber [I&I 26+]



## Le recouvrement reformulé en percolation


- **Recouvrement faible** : battre asymptotiquement le hasard —  $ov \geq \frac{1}{2} + \eta$  ( $\eta > 0$ )

**Théorème [Sankararaman-Baccelli 18]** : la **percolation** du modèle à connexion  $f_{\text{in}} - f_{\text{out}}$  est une condition **nécessaire** au recouvrement faible


- Dans notre cadre bayésien, **sans percolation des amas gelés, pas de recouvrement**
- Avec la dynamique de SWENDSEN–WANG classique : on **retrouve exactement** leur théorème (le gel est une percolation  $f_{\text{in}} - f_{\text{out}}$ ) [I&I 26+]
- Avec la dynamique **triangulaire** : borne **strictement améliorée** (sur la grille triangulaire :  $p_c$  passe de 0,674 à 0,719) [I&I 26+]




## Extraction de réseaux de fissures sur images




intensité



profondeur



similarité du graphe



squelette extrait

- Du **pixel** (filtre de FRANGI [Frangi 98]) à la **paire de pixels** (graphe de Frangi [GRETSI 25])
- **Multimodal**, sans apprentissage ; la connexité  $K = 2$  bloque la percolation du bruit [EUVIP 26]
- Robuste hors distribution ; la sortie est un **graphe éditable** [ISPRS 26+]

[Frangi 98] A. F. Frangi, W. J. Niessen, K. L. Vincken, M. A. Viergever, « Multiscale vessel enhancement filtering », MICCAI, 1998.


[GRETSI 25] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Généralisation du filtre de Frangi pour l'extraction des réseaux de fissures », GRETSI, 2025.

[EUVIP 26] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.

[ISPRS 26+] L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, article en préparation pour ISPRS Journal of Photogrammetry and Remote Sensing, 2026.



## Et ensuite ? Guider un modèle de fondation



Un réseau entièrement manqué par la baseline, retrouvé (IoU  
 $0 \rightarrow 0,22$ )

- ▶ SAM 2 [SAM 2 24] + LoRA + **11 canaux d'évidence géométrique**, injectés à initialisation nulle
- ▶ Acquis : la **perte tolérante** (3 px), issue de l'incertitude d'annotation, bat la baseline
- ▶ Contrôle causal (évidence permutée) : en monomodal, la géométrie n'ajoute rien...
- ▶ ... la perspective : le **multimodal**, où SAM n'a pas accès à cette information [ISPRS 26+]


07

## Perspectives : la voie hiérarchique





# Une parabole : le théorème d'impossibilité de Kleinberg




- **Théorème [Kleinberg 02]** : aucune fonction de clustering rendant une **partition** ne satisfait ces trois axiomes à la fois
- L'obstruction n'est pas levée, elle est **contournée** : on ne relâche aucun axiome, on change l'*objet rendu* — l'arbre, et non la coupe
- [Carlsson-Mémoli 10] : sur les **ultramétries**, une axiomatique *analogue* ne laisse survivre qu'un seul algorithme

[Kleinberg 02] J. Kleinberg, « An impossibility theorem for clustering », *NeurIPS*, 2002.

[Carlsson-Mémoli 10] G. Carlsson, F. Mémoli, « Characterization, stability and convergence of hierarchical clustering methods », *JMLR*, 2010.

# La chaîne continue : du recouvrement aux polyèdres




- [Culbertson 18] pousse la même logique un cran plus loin : remplacer la partition par un **recouvrement**. Pour  $K \geq 2$ , c'est exactement ce que rend HGP-Clusterer [ANS 26]
- Un nœud n'est plus un sac de points : c'est un recollement de facettes, *i.e.* une **surface**. Le manuscrit écrit : *un recouvrement de  $\mathcal{X}$ , ou bien une partition des  $(K - 1)$ -simplexes*

Deux acquis exportables : des **polyèdres**, et surtout une **hiérarchie**

[Culbertson 18] J. Culbertson, D. P. Guralnik, P. F. Stiller, « Functorial hierarchical clustering with overlaps », *Discrete Applied Mathematics*, 2018.



# Un manque : pas encore de modèle de fondation pour la 3D



- ▶ Le langage [GPT-3 20] et l'image [SAM 2 24] ont chacun une **unité de calcul stable**
- ▶ En 3D l'effort est réel — Sonata [Sonata 25], Concerto [Concerto 25], Utonia [Utonia 26] — mais il porte sur des **points** ou des voxels, et rien, à ma connaissance, ne fait encore **consensus**

[GPT-3 20] T. Brown & al., « Language models are few-shot learners », *NeurIPS*, 2020.


[Sonata 25] X. Wu & al., « Sonata : self-supervised learning of reliable point representations », *CVPR*, 2025.

[Concerto 25] Y. Zhang & al., « Concerto : joint 2D–3D self-supervised learning emerges spatial representations », *NeurIPS*, 2025.

[Utonia 26] Y. Zhang & al., « Utonia : toward one encoder for all point clouds », 2026.



## Un verrou : le nuage de points est un artefact du capteur




- ▶ **Discrétisation** dictée par le capteur : nappes de balayage, résolution angulaire, rémission
- ▶ **Densité** qui décroît avec la portée : le même objet donne deux nuages incomparables
- ▶ **Occultations** : ce qui manque n'est pas vide, il est *non observé*
- ▶ Un modèle *point-wise* apprend donc *en même temps* la géométrie, le capteur, la densité, l'occultation et la sémantique

Hypothèse assumée : c'est *une* raison centrale de la difficulté — pas la seule



## La piste : le polyèdre comme alphabet, l'arbre comme grammaire



- ▶ **Chaque** nœud porte une surface *observée*, et pas seulement les feuilles — ce que ne font ni les hiérarchies de régions [SPT 23], ni l'apprentissage sur polyèdres complets [PolyhedronNet 25]
- ▶ Le niveau de la filtration est une grandeur **physique** — un rayon, donc une densité : les branches deviennent des trajectoires, les fusions des événements
- ▶ La *forme* se normalise — par **similitude** : ce n'est pas encore une robustesse à la portée — et taille, pose et acquisition restent des canaux séparés


[SPT 23] D. Robert, H. Raguét, L. Landrieu, « Efficient 3D semantic segmentation with Superpoint Transformer », *ICCV*, 2023.

[PolyhedronNet 25] D. Yu, G. Zhang, L. Zhao, « PolyhedronNet : representation learning for polyhedra with surface-attributed graph », *ICLR*, 2025.





## Une contre-épreuve : la hiérarchie ne s'impose pas de l'extérieur




- Idée testée : une fissure est définie par sa **connexité**, or l'attention n'a aucun *a priori* de chemin — contrainsons-la par la hiérarchie du graphe de FRANGI [HSA 25]
- **Non** — et sans une seconde de GPU : ce mécanisme *comprime* une attention sous contrainte de blocs, quand il fallait y *injecter* un *a priori*
- L'endroit reste le bon ; c'est l'outil qui ne l'est pas — et ce qu'il faudrait injecter, ici comme en 3D, c'est la *hiérarchie* du graphe, jamais sa projection en carte

La hiérarchie doit être **l'alphabet** du modèle, non une contrainte ajoutée après coup

[HSA 25] S. Amizadeh, S. Abdali, Y. Li, K. Koishida, « Hierarchical self-attention : generalizing neural attention mechanics to multi-scale problems », *NeurIPS*, 2025.



## Rester honnête : ce qui reste entièrement à démontrer



Le mot « **modèle de fondation** » n'est pas revendiqué :  
il désigne ici le point d'arrivée d'un programme de **réfutation**, pas un résultat

- ▶ Le **tokenizer** existe — c'est la thèse ; le **modèle**, lui, n'est pas écrit, et aucune expérience n'a été menée
- ▶ La porte n° 4 est la plus dangereuse : si l'arbre réel ne bat ni le modèle plat, ni un arbre aléatoire, ni un octree, le pari hiérarchique tombe
- ▶ Difficulté connue d'avance : la marge est sur les objets **filiformes** (poteaux, panneaux), or la connexité d'ordre  $K$  les fait naître *tard* dans la filtration

Si un modèle de fondation doit émerger pour la 3D, sur quelle représentation ? C'est la question que j'ouvre

# 08

## Conclusion





## Deux piliers, quatre contributions

1) Quand les relations binaires sont insuffisantes ou instables, les **interactions d'ordre supérieur** apportent une cohérence robuste.

2) La **percolation** est la clef de voûte théorique pour quantifier les performances de ces algorithmes

- ▶ Une **vue unifiée** du Single-Linkage : heuristique (arbre couvrant), géométrique (percolation), statistique (HARTIGAN), avec applications LiDAR 3D/4D sans apprentissage [ANS 26]
- ▶ **HGP-Clusterer** : la hiérarchie  $K$ -NN exacte, via Čech, GABRIEL et la mosaïque de DELAUNAY d'ordre  $K$  [EUSIPCO 24] [CN 24]
- ▶ La **vitesse de percolation** : une mesure quantitative qui explique l'échec de Robust SL / (H)DBSCAN et la supériorité des  $K$ -polyèdres [Sigm SRC 24]
- ▶ L'**export du paradigme** : graphes signés (dynamiques d'ordre supérieur, bornes plus fines) [Asilomar 25] et imagerie (graphe de Frangi multimodal) [GRETSI 25] [EUVIP 26]



## Perspectives, dans le fil de la thèse

- ▶ **Réduction de dimension d'ordre supérieur** : la mosaïque de DELAUNAY d'ordre  $K$  est bien plus riche que les graphes de voisinage (UMAP) : la piste privilégiée à court terme
- ▶ **Question ouverte assumée** : HGP-Clusterer n'est que *fractionnellement* consistant ; un algorithme consistant en dimension  $p \geq 2$  reste à inventer
- ▶ **Graphes signés** : couplage à deux répliques pour des seuils exacts de recouvrement ; vers un algorithme pratique de détection de communautés
- ▶ **Fissures** : un logiciel d'aide à l'annotation experte fondé sur les graphes ; réconcilier modèles géométriques et apprentissage profond
- ▶ **Et, plus loin** : la *voie hiérarchique* qui précède — faire du polyèdre et de son espace d'échelle l'unité de calcul d'un modèle appris pour la 3D

# Publications

## Journal

- ▶ **[ANS 26]** *Generalization of Single-Linkage with higher-order interactions*, Applied Network Science, 2026

## Conférences internationales et nationales

- ▶ **[CN 23]** Filaments de galaxies, Complex Networks, Menton, 2023
- ▶ **[EUSIPCO 24]** Hypergraphes pour le clustering par densité, EUSIPCO, Lyon, 2024
- ▶ **[CN 24]** Hypergraphes, percolation et clustering hiérarchique, Complex Networks, Istanbul, 2024
- ▶ **[Sigm SRC 24]** Mesure théorique de performance, ACM SIGMETRICS SRC, Venise, 2024 (**2<sup>e</sup> prix**)
- ▶ **[Asilomar 25]** Dynamiques de clusters d'ordre supérieur, Asilomar, 2025
- ▶ **[GRETSI 25]** Généralisation du filtre de Frangi, GRETSI, Strasbourg, 2025
- ▶ **[EUVIP 26]** Extraction multimodale de fissures sans apprentissage, EUVIP, Luxembourg, 2026

## En cours

- ▶ **[I&I 26+]** Cadre bayésien pour la détection de communautés sur graphes signés (journal)
- ▶ **[ISPRS 26+]** Graphe de Frangi généralisé, multimodal et sans apprentissage (journal ISPRS)

**Logiciel** : dépôts GitHub Ayana-Inria/HypergraphPercol\_K2 et Ayana-Inria/Frangi-EUVIP

*Merci.*





## Travaux de l'auteur présentés aujourd'hui

- ▶ **[HAL 17]** L. Hauseux (encadré par B. Błaszczyszyn), « Un classificateur non-supervisé utilisant les complexes simpliciaux », Inria Paris, 2017. HAL : hal-01597846.
- ▶ **[CN 23]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Graph based approach for galaxy filament extraction », *Complex Networks & Their Applications*, Menton, 2023.
- ▶ **[EUSIPCO 24]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Benefits of hypergraphs for density-based clustering », *EUSIPCO*, Lyon, 2024.
- ▶ **[CN 24]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Hypergraphs, percolation and hierarchical clustering », *Complex Networks & Their Applications*, Istanbul, 2024.
- ▶ **[Sigm SRC 24]** L. Hauseux, « How can we theoretically measure the performance of density-based clustering algorithms? », ACM SIGMETRICS SRC, Venise, 2024 (2<sup>e</sup> prix).
- ▶ **[ANS 26]** L. Hauseux, K. Avrachenkov, J. Zerubia, « Generalization of Single-Linkage with higher-order interactions », *Applied Network Science*, 11(9), 2026.
- ▶ **[GRETSI 25]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Généralisation du filtre de Frangi pour l'extraction des réseaux de fissures », GRETSI, 2025.
- ▶ **[Asilomar 25]** L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « Higher-order Monte Carlo cluster dynamics for community detection in Euclidean graphs », Asilomar, 2025.
- ▶ **[EUVIP 26]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, « Multi-modal, training-free crack extraction via generalized Frangi graph », EUVIP, 2026.
- ▶ **[I&I 26+]** L. Hauseux, N. Soprano-Loto, K. Avrachenkov, « A Bayesian framework for community detection on signed graphs », article de journal en cours de rédaction, 2026.
- ▶ **[ISPRS 26+]** L. Hauseux, R. Antoine, P. Foucher, P. Charbonnier, J. Zerubia, article en préparation pour ISPRS Journal of Photogrammetry and Remote Sensing, 2026.





## Bibliographie (1/2)

- ▶ [Florek 51] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, S. Zubrzycki, « Sur la liaison et la division des points d'un ensemble fini », *Colloq. Math.*, 1951.
- ▶ [Gower-Ross 69] J. C. Gower, G. J. S. Ross, « Minimum spanning trees and Single-Linkage cluster analysis », *JRSS C*, 1969.
- ▶ [Hartigan 81] J. A. Hartigan, « Consistency of Single Linkage for high-density clusters », *JASA*, 1981.
- ▶ [Forina 83] M. Forina, C. Armanino, S. Lanteri, E. Tiscornia, « Classification of olive oils from their fatty acid composition », 1983 (jeu de données).
- ▶ [Swendsen-Wang 87] R. H. Swendsen, J.-S. Wang, « Nonuniversal critical dynamics in Monte Carlo simulations », *Physical Review Letters*, 1987.
- ▶ [Ester 96] M. Ester, H.-P. Kriegel, J. Sander, X. Xu, « A density-based algorithm for discovering clusters » (DBSCAN), *KDD*, 1996.
- ▶ [Frangi 98] A. F. Frangi, W. J. Niessen, K. L. Vincken, M. A. Viergever, « Multiscale vessel enhancement filtering », *MICCAI*, 1998.
- ▶ [Kleinberg 02] J. Kleinberg, « An impossibility theorem for clustering », *NeurIPS*, 2002.
- ▶ [Penrose 03] M. Penrose, *Random Geometric Graphs*, Oxford University Press, 2003.
- ▶ [Ghrist 08] R. Ghrist, « Barcodes : the persistent topology of data », *Bulletin of the AMS*, 2008.
- ▶ [Chaudhuri-Dasgupta 10] K. Chaudhuri, S. Dasgupta, « Rates of convergence for the cluster tree », *NeurIPS*, 2010.
- ▶ [Carlsson-Mémoli 10] G. Carlsson, F. Mémoli, « Characterization, stability and convergence of hierarchical clustering methods », *JMLR*, 2010.
- ▶ [Campello 13] R. Campello, D. Moulavi, J. Sander, « Density-based clustering based on hierarchical density estimates » (HDBSCAN), *PAKDD*, 2013.



## Bibliographie (2/2)


- ▶ [Boissonnat 18] J.-D. Boissonnat, F. Chazal, M. Yvinec, *Geometric and Topological Inference*, Cambridge University Press, 2018.
- ▶ [Culbertson 18] J. Culbertson, D. P. Guralnik, P. F. Stiller, « Functorial hierarchical clustering with overlaps », *Discrete Applied Mathematics*, 2018.
- ▶ [Sankararaman-Baccelli 18] A. Sankararaman, F. Baccelli, « Community detection on Euclidean random graphs », *ACM-SIAM SODA*, 2018.
- ▶ [GPT-3 20] T. Brown & al., « Language models are few-shot learners », *NeurIPS*, 2020.
- ▶ [Edelsbrunner-Osang 23] H. Edelsbrunner, G. Osang, « A simple algorithm for higher-order Delaunay mosaics and alpha shapes », *Algorithmica*, 2023.
- ▶ [SPT 23] D. Robert, H. Raguét, L. Landrieu, « Efficient 3D semantic segmentation with Superpoint Transformer », *ICCV*, 2023.
- ▶ [Rolle-Scoccola 23] A. Rolle, L. Scoccola, « Stable and consistent density-based clustering » (Persistable), *JMLR*, 2024.
- ▶ [SAM 2 24] N. Ravi & al., « SAM 2 : segment anything in images and videos », 2024.
- ▶ [Sautier 25] C. Sautier & al., « Alpine : is clustering enough for LiDAR instance segmentation ? », 2025.
- ▶ [Oh 25] M. Oh & al., « Geo-4D : training-free global geometric association for 4D LiDAR panoptic segmentation », 2025.
- ▶ [Sonata 25] X. Wu & al., « Sonata : self-supervised learning of reliable point representations », *CVPR*, 2025.
- ▶ [Concerto 25] Y. Zhang & al., « Concerto : joint 2D-3D self-supervised learning emerges spatial representations », *NeurIPS*, 2025.
- ▶ [PolyhedronNet 25] D. Yu, G. Zhang, L. Zhao, « PolyhedronNet : representation learning for polyhedra with surface-attributed graph », *ICLR*, 2025.
- ▶ [HSA 25] S. Amizadeh, S. Abdali, Y. Li, K. Koishida, « Hierarchical self-attention : generalizing neural attention mechanics to multi-scale problems », *NeurIPS*, 2025.
- ▶ [Utonia 26] Y. Zhang & al., « Utonia : toward one encoder for all point clouds », 2026.

# Slides de secours






## Stylométrie 2017 : le cas à 5 auteurs



- ▶ 5 auteurs  $\times$  40 textes ( $P = 70\%$ ,  $k = 5$ )
- ▶ 4 classes correctement identifiées...
- ▶ ... mais la 4<sup>e</sup> (textes 120–159) est manquée
- ▶ Ronds noirs : non classés ; étoiles : multi-classes

# Benchmark SIPU : toutes choses égales par ailleurs



Même  $\text{min\_cluster\_size} = \sqrt{n}$ , même excès de masse :  
la seule différence est la **connexité triangulaire**

| Jeu    | HDBSCAN | 2-polyèdres  |
|--------|---------|--------------|
| a2     | 0,762   | <b>0,834</b> |
| a3     | 0,696   | <b>0,831</b> |
| d31    | 0,660   | <b>0,835</b> |
| s2     | 0,780   | <b>0,842</b> |
| s3     | 0,251   | <b>0,418</b> |
| birch2 | 0,996   | <b>0,998</b> |

RI ; grille : vérité, HDBSCAN, notre algorithme



## Huiles d'olive : la matrice de confusion

| Pers./Ours       | 1     | 2    | 3       | 4 | 5     | 6     | 7     | 8     | 9     | Miss.  |
|------------------|-------|------|---------|---|-------|-------|-------|-------|-------|--------|
| <b>N. Apulia</b> | 12/24 | 0/0  | 0/0     | - | 0/0   | 0/0   | 0/0   | 0/0   | 0/0   | 13/1   |
| <b>Calabria</b>  | 0/0   | 7/25 | 1/2     | - | 0/0   | 0/0   | 0/0   | 0/0   | 0/0   | 48/29  |
| <b>S. Apulia</b> | 0/0   | 0/0  | 100/145 | - | 0/0   | 0/0   | 0/0   | 0/0   | 0/0   | 106/61 |
| <b>Sicilia</b>   | 3/6   | 0/1  | 0/2     | - | 0/0   | 0/0   | 0/0   | 0/0   | 0/0   | 33/27  |
| Inl. Sard.       | 0/0   | 0/0  | 0/0     | - | 51/62 | 0/0   | 0/0   | 0/0   | 0/0   | 14/3   |
| Coast S.         | 0/0   | 0/0  | 0/0     | - | 0/2   | 19/29 | 0/0   | 0/0   | 0/0   | 14/2   |
| <b>E. Ligur.</b> | 0/0   | 0/0  | 0/0     | - | 0/0   | 0/0   | 14/32 | 1/2   | 0/1   | 35/15  |
| <b>W. Ligur.</b> | 0/0   | 0/0  | 0/0     | - | 0/0   | 0/0   | 0/0   | 29/33 | 0/0   | 21/17  |
| <b>Umbria</b>    | 0/0   | 0/0  | 0/0     | - | 0/0   | 0/0   | 0/0   | 0/0   | 42/46 | 9/5    |

- ▶ 412/572 points classés (72 %), dont 96,1 % correctement
- ▶ Persistable [Rolle-Scoccola 23] : 49 % classés seulement
- ▶ En partition exhaustive : ARI 0,890 contre 0,848




## Vitesses de percolation : le protocole

- ▶  $\mathcal{X}$  :  $n = 100\,000$  points uniformes dans  $\left[0, n^{1/p}\right]^p$  ( $n = 10\,000$  en dimension 4)
- ▶  $T = 100$  tirages indépendants ; rappel  $\varepsilon = 3\%$
- ▶ Pour chaque algorithme (HGP, Robust SL, DBSCAN) : rayons de fusion et taille de la plus grande composante
- ▶ Estimateur  $\hat{v} = \hat{\lambda}_\varepsilon / \hat{\lambda}_{1-\varepsilon}$
- ▶ Repère : seuil critique du modèle booléen ( $K = 1$ , 2D) :  $\lambda_c \approx 1,44$




## Vitesses de percolation : Robust Single-Linkage et DBSCAN



Robust Single-Linkage : la percolation converge trop lentement vers

1



DBSCAN : la frontière est réintégrée, mais les cœurs percolent trop

tôt







## Quand $K \rightarrow +\infty$ : la fenêtre gaussienne

- ▶ Dans la fenêtre  $\mu = K + a\sqrt{K}$ , les niveaux  $K$ -NN convergent vers les **excursions**  $E_a = \{G_p \geq -a\}$  d'un champ gaussien
- ▶ Covariance du champ : le volume d'intersection de deux boules
- ▶ Les trois algorithmes ne diffèrent que par l'**ordre des opérations** : dilater puis connecter (cœurs, DBSCAN) vs. connecter puis dilater (polyèdres)
- ▶ Seuils de bruit :  $a_c^{\text{poly}} \geq a_c^{\text{core}}$ , vitesse asymptotiquement meilleure pour les  $K$ -polyèdres

# L'état de l'art LiDAR



Alpine [Sautier 25] : « is clustering enough ? »



Geo-4D [Oh 25] : association géométrique 4D




# L'assemblage d'haplotypes

## Un graphe signé bruité


Nœuds = lectures ADN ; arêtes = chevauchements (attractions / répulsions)

**But** : retrouver l'affectation cachée  $\Sigma$





## Le cadre bayésien et l'hypothèse de Gibbs



$$U(\sigma) = \sum_{e \in F} W_e \mathbb{I}_{\{\sigma_i \neq \sigma_j\}} + \sum_{e \in \tilde{F}} |W_e| \mathbb{I}_{\{\sigma_i = \sigma_j\}} \quad \mu_{X,W}(\sigma) = \frac{e^{-U(\sigma)}}{Z}$$

- ▶  $F$  : arêtes attractives ( $W_e > 0$ );  $\tilde{F}$  : répulsives ( $W_e < 0$ );  $U$  pénalise les arêtes insatisfaites
- ▶ **Hypothèse de Gibbs** : la loi *a posteriori* est la mesure de Gibbs signée



## Un pas de Swendsen–Wang signé, en détail

- ▶ **Gel** : chaque arête *satisfaite* est gelée avec probabilité  $1 - e^{-|W_e|}$  ; les insatisfaites jamais
- ▶ **Recoloriage** : chaque amas gelé est recolorié uniformément au hasard
- ▶ La dynamique laisse la loi *a posteriori* invariante
- ▶ Un pas depuis la vérité  $\Sigma$  produit une **réplique**  $\Sigma^{(1)} \sim \mu_{X,W}$  (identité de Nishimori) : un couplage entre vérité et observation
- ▶ Les petits amas sont recoloriés aveuglément : l'information globale ne survit que dans les **composantes géantes**



## Le modèle de Sankararaman–Bacelli, en détail

- ▶ Nœuds : processus de Poisson dans  $\mathbb{R}^p$  ; communautés  $\Sigma_i \in \{\pm 1\}$  uniformes
- ▶ Arête  $e = \{i, j\}$  présente avec probabilité  $f_{\text{in}}(r_e)$  (même communauté) ou  $f_{\text{out}}(r_e)$  (communautés différentes),  $r_e = \|X_i - X_j\|$
- ▶ Poids signés reconstruits :  $W_e = \log \frac{f_{\text{in}}(r_e)}{f_{\text{out}}(r_e)} \geq 0$  si  $e$  observée,  $W_e = -\log \frac{1-f_{\text{out}}(r_e)}{1-f_{\text{in}}(r_e)} \leq 0$  sinon

$$\mathbb{P}(\text{arête gelée}) = f_{\text{in}}(r_e) \left(1 - e^{-|W_e|}\right) = f_{\text{in}}(r_e) - f_{\text{out}}(r_e)$$

- ▶ Le graphe gelé d'un pas de SW-arêtes est **exactement** la percolation indépendante de [Sankararaman-Bacelli 18]




## La hiérarchie d'horloges, en détail

- ▶ Conditionnellement à  $\sigma : \xi_e \sim \text{Exp}(|W_e|)$  sur les arêtes satisfaites,  $\xi_e = +\infty$  sinon ;  $\Pi_\beta =$  composantes de  $\{\xi_e \leq \beta\}$  ; le dendrogramme s'obtient par KRUSKAL
- ▶  $\mathbb{P}(\xi_e \leq 1) = 1 - e^{-|W_e|}$  :  $\Pi_1$  est **exactement** la partition gelée de Swendsen–Wang
- ▶ Mesure jointe de type EDWARDS–SOKAL  $\nu(\sigma, D)$  ; à chaque nœud, un **heat bath exact** sur les quatre orientations relatives des deux fils (balance détaillée, invariance)
- ▶ Le dendrogramme est **non marqué** : l'identité de l'arête gagnante est marginalisée — une fusion dépend de toute la coupe  $\Lambda_u(\sigma) = \sum_{e \in E_u} |W_e| \mathbb{I}_{\{e \text{ satisfaite}\}}$
- ▶ Sur le tore triangulaire :  $\Pi_t$  suit une percolation indépendante  $q_p(t) = p(1 - e^{-u_p t})$ ,  
 $u_p = \log \frac{p}{1-p}$



# L'échelle des seuils du GSBM triangulaire




- Gel SW  $0,6736 < \text{triangles } 0,7192 < \text{info-percolation } 0,7947 < \text{record rigoureux } 0,8094$
- Point multicritique de Nishimori  $0,8358$  : conjecture





# Calibration exacte sur le SBM




► Deux répliques, deux dendrogrammes **indépendants**, coupés au même  $\beta_c$

► Chaque arête transmet exactement  $\theta^2$  :  
calibration  $\beta_X = \beta_c \Leftrightarrow d\theta^2 = 1$   
(le seuil de KESTEN-STIGUM)

► Quand le signal diverge,  $\beta_{c,n} \rightarrow 0$  : la coupe s'écrase d'elle-même sur Glauber




## Validation à $10^6$ nœuds : les trois régimes



$p = 0,70$  : seules les arêtes standard percolent ; l'*overlap* reste au bruit




## Validation à $10^6$ nœuds : les trois régimes



$p = 0,72$  : toutes les dynamiques percolent... mais l'*overlap* reste au bruit (nécessaire  $\neq$  suffisant)




## Validation à $10^6$ nœuds : les trois régimes



$p = 0,80$  : composantes géantes stables et **recouvrement effectif**





## VT-GraF : la connexité $K = 2$ sur le terrain



- ▶ Visible granulaire + thermique : la réponse de Frangi seule est noyée dans les cailloux
- ▶ Les composantes triangles-connexes éliminent les artefacts granulaires



## Sans entraînement... et robuste




Sous bruit croissant, notre méthode (rouge) reste stable

Vaches Noires : vérité (vert), nous (rouge), U-Net (bleu)


- ▶ Compétitif avec un U-Net ayant coûté deux jours d'annotation experte
- ▶ CrackSegDiff : 87 % vs. 63 % de Jaccard sur données propres... mais s'effondre hors distribution



## Transferts sans réentraînement




Palais des Papes : la fracture principale



CrackForest : Jaccard 78 %, Wasserstein 5 px



## Sensibilité aux paramètres




Seuil relatif  $\tau$  : optimum net vers  $\tau \approx 0,2$  (graphe fragmenté vs. ponts parasites)






# CrackSAM-GeoLoRA : le protocole causal




Six variantes, IoU stricte sur 1 695 images de test (corpus Khánh Hà)



Évidence alignée vs. permutée : sur la diagonale

- Baseline 0,6241 ; perte tolérante 0,6276 ; géométrie + tolérance 0,6270  $\approx$  évidence permutée 0,6265
- $|\Delta| < 0,001$  à toutes les tolérances : en monomodal, la géométrie n'apporte pas d'information nouvelle

## Voie hiérarchique : ce que la thèse fournit déjà



Le pari : le **tokenizer** est déjà là ; c'est le modèle qui reste à écrire

- ▶ Ce que la hiérarchie sérialise pour chaque nœud : la surface (facettes, aires, normales, bords), le niveau de naissance, le parent, les enfants de fusion, les voisins latéraux et la confiance d'acquisition
- ▶ L'interface vers les points existe déjà : le vote pondéré  $w_{x\tau} = S_\tau / T_x$  du § 9.1, qui est une partition de l'unité
- ▶ Ce qui manque est en aval : encodeur de surface, encodeur de branche, encodeur de fusion, décodeur par facette — et les campagnes qui les jugeraient



## Voie hiérarchique : pourquoi le *no-go* est un *no-go* de conception



ce que HSA exige  
arité  $b \simeq 8$ , profondeur  $\log_b N \simeq 4,5$



ce que donne le graphe de Frangi  
arité  $b \simeq 1,3$ , profondeur 358

une fissure est une **chenille** : 72 % des nœuds n'ont qu'un seul enfant

- ▶ **Surface d'attaque** : 3 blocs d'attention globale sur 48 dans Hiera-L, soit 6,56 % des opérations du tronc
- ▶ **Forme de l'arbre** : 72 % des nœuds internes n'ont qu'un seul enfant ; l'arité  $b = (N - 1)/(N - L)$  est *fixée* par la fraction de feuilles, ce n'est pas un réglage
- ▶ Ce défaut-là se répare (décomposition en centroïdes : profondeur 12, arité 2,82) ; ce qui ne se répare pas, c'est qu'une contrainte de blocs *comprime* au lieu d'informer
- ▶ **Limite assumée** : mesures sur fissures *synthétiques* calibrées sur le corpus Khánh Hà (448 px, largeur 19 px, couverture 5,7 %)



## Voie hiérarchique : comment saurais-je que c'est l'arbre qui aide ?

| Bras      | Structure                                               |
|-----------|---------------------------------------------------------|
| H0        | polyèdres indépendants                                  |
| H1        | graphe latéral seulement                                |
| H2        | arbre aléatoire apparié<br>(profondeur, degrés, masses) |
| H3        | octree / arbre de voxels                                |
| H4        | HDBSCAN / Robust SL                                     |
| H5        | niveaux HGP permutés                                    |
| H6        | topologie HGP sans les niveaux                          |
| <b>H7</b> | <b>trajectoires HGP complètes</b>                       |
| H8        | H7 + événements + latéral                               |

À tokenizer, paramètres et budget **appariés**, trois lectures suffisent à réfuter le pari :

- ▶  $H6 \approx H7$  : les **niveaux** de densité n'apportent rien
- ▶  $H4 \approx H7$  : une hiérarchie **générique** suffit
- ▶  $H1 \approx H8$  : le **graphe spatial** explique tout

Ces résultats resteraient publiables comme **réfutation**  
— mais pas sous le *claim* prévu.



## Voie hiérarchique : efficacité *contre* continuité, en chiffres

| Hiérarchie candidate              | Profondeur | Arité | Dilution à longue portée |
|-----------------------------------|------------|-------|--------------------------|
| <b>sémantique</b> {fissure, fond} | 10,3       | 3,17  | <b>181</b>               |
| <i>son contrôle permuté</i>       | 10,0       | 3,23  | 808                      |
| coupe spatiale <i>min-cut</i>     | 9,3        | 2,75  | 768                      |
| FRANGI + centroïdes               | 12,0       | 2,82  | 1 013                    |
| <i>quadtree</i>                   | 7,0        | 4,00  | 1 024                    |
| aléatoire                         | 7,0        | 4,00  | 1 024                    |

- ▶ **Dilution** : combien de jetons sont moyennés avec  $j$  quand  $i$  l'attend. Sous attention plate, elle vaut 1 — 181 reste donc *énorme*
- ▶ L'écart 181 contre 808 mesure la **causalité** (bon masque vs. masque d'une autre image), pas une performance : aucun IoU n'a été mesuré
- ▶ Toutes les hiérarchies **équilibrées** plafonnent entre 768 et 1 024, y compris celle qui cherche explicitement à éviter la fissure